

Отчёт по семинару

QIIME2, метагеномика микробиоты мышей (mice)

Анна Шифон

22 сентября 2026 г.

Введение

Данные из работы Rosshart et al. (*Cell*, 2017), разбираемой на семинаре: germ-free мышам C57BL/6 пересаживали лабораторную (LabR) или дикую (WildR) микробиоту и затем сравнивали устойчивость к гриппу H1N1 и к колоректальному раку. Группы: L и W – доноры (лабораторные и дикие мыши), LR и WR – germ-free реципиенты, получившие микробиоту L и W соответственно (LabR и WildR). Всего 29 образцов, секвенирование гена 16S rRNA paired-end, Illumina, 2×250 нт. Анализ выполнен в QIIME2 (Singularity, образ qiime2-amplicon:2024.10) на удалённом сервере.

- **Источник ДНК.** Секвенировали не РНК, а ген 16S rRNA в составе бактериальной геномной ДНК, выделенной из кишечной микробиоты мышей.
- **Регион и его длина.** Гипервариабельный участок V4 гена 16S rRNA; ампликон с праймерами ≈ 291 п.н. (без праймеров ≈ 252 п.н., см. раздел 3).
- **Длина ридов.** Illumina MiSeq, paired-end 2×250 нт.
- **Праймеры.** Универсальная бактериальная пара 515F/806R:
515F – 5'-GTGCCAGCMGCCGCGGTAA-3',
806R – 5'-GGACTACHVGGGTWTCTAAT-3'; в реальных ридах к ним добавлены Illumina-адаптеры и баркоды образцов.
- **Буквы N, H, Y в праймерах.** Вырожденные позиции по коду IUPAC: N = A/C/G/T (любой), H = A/C/T (не G), Y = C/T (пиримидин). Они нужны, чтобы один набор праймеров связывался с 16S-последовательностями многих разных бактерий.
- **Почему V4.** При длине ампликона ≈ 291 п.н. два рида по 250 нт сильно перекрываются и надёжно сшиваются DADA2; при этом V4 – достаточно вариабельный участок для различения бактериальных таксонов.

1 Контроль качества (FastQC + MultiQC)

FastQC запущен для всех 58 fastq-файлов (29 образцов $\times$ forward/reverse), результаты объединены в отчёт MultiQC.




Рис. 1: Общая статистика MultiQC: процент дубликатов и GC-состав (фрагмент таблицы, первые 16 из 58 файлов).




Рис. 2: Качество прочтений по позициям (Sequence Quality Histograms), все 58 файлов.

- Среднее качество держится около Phred 35 в первых ~150 нуклеотидах, затем падает до 15–20 и ниже к 200–250 п.н. – обычная картина для Illumina.
- Высокая доля дубликатов (75–90%) характерна для ампликонного секвенирования: один и тот же участок 16S закономерно повторяется у разных особей одного вида. Это не признак проблем с библиотекой.
- GC-состав стабилен (~52–54%) во всех образцах.

2 Импорт данных и статистика прочтений

Данные импортированы как `SampleData[PairedEndSequencesWithQuality]` (manifest-формат `PairedEndFastqManifestPhred33V2`), затем построена `demux summarize`.

Demultiplexed sequence counts summary

	forward reads	reverse reads
Minimum	2138	2138
Median	4918.0	4918.0
Mean	4643.862069	4643.862069
Maximum	6394	6394
Total	134672	134672

Рис. 3: Сводная статистика числа прочтений (`demux summarize`), 29 образцов.




Рис. 4: Interactive Quality Plot: качество forward и reverse прочтений (случайная подвыборка 10 000 прочтений).

- Всего 134 672 прочтения; на образец от 2138 до 6394, медиана 4918, среднее 4644, то есть распределение не перекошено выбросами.
- Forward-прочтения сохраняют высокое качество до ~200–210 п.н. Reverse ухудшаются раньше (заметно после ~180–190 п.н., резкий провал около 200 п.н.). По графику выбраны параметры обрезки для DADA2: `--p-trunc-len-f 220`, `--p-trunc-len-r 200`.

3 Денойзинг DADA2

Запущена команда:

```
qiime dada2 denoise-paired --p-trim-left-f 0 --p-trim-left-r 0
--p-trunc-len-f 220 --p-trunc-len-r 200
```

QIIME 2

File: mice_reads.dada2.stats.qzv

Visualization Citations Provenance Metadata

Download metadata TSV file

This file won't necessarily reflect dynamic sorting or filtering options based on the interactive table below.

Search:

sample-id	input	filtered	percentage of input passed filter	denoised	merged	percentage of input merged	non-chimeric	percentage of input non-chimeric
#q2-types	numeric	numeric	numeric	numeric	numeric	numeric	numeric	numeric
L1	3773	3093	81.98	2961	2731	72.38	2697	71.48
L2	3669	2972	81	2825	2482	67.65	2482	67.65
L3	5346	4380	81.93	4218	3710	69.4	3449	64.52
L4	3836	2964	77.27	2805	2508	65.38	2455	64
L5	3311	2529	76.38	2397	2123	64.12	2065	62.37
L6	4572	3615	79.07	3424	3116	68.15	3105	67.91
L7	4536	3602	79.41	3443	3082	67.95	3070	67.68
L8	3498	2659	76.01	2528	2278	65.12	2278	65.12
LR1	5047	4410	87.38	4246	3878	76.84	3867	76.62
LR2	6394	5508	86.14	5358	4811	75.24	4811	75.24
LR3	5753	4861	84.5	4633	4157	72.26	4157	72.26
LR4	6062	5134	84.69	4969	4516	74.5	4489	74.05
LR5	6056	5110	84.38	4963	4635	76.54	4635	76.54

Рис. 5: Статистика DADA2: input → filtered → denoised → merged → non-chimeric.

--p-trim-left-f/-r 0 выбраны по качеству прочтений (Рис. 4): в отличие от почвенного задания, здесь не проверялось отдельно по Per base sequence content в MultiQC, действительно ли праймеры 515F/806R отсутствуют в начале ридов R1/R2. Если бы они были на месте, потребовалось бы примерно --p-trim-left-f 19 и --p-trim-left-r 20; это стоит проверить дополнительно.

Проверка перекрытия: праймеры не обрезаны (--p-trim-left-f/-r 0), поэтому релевантна длина ампликона с праймерами, ≈ 291 п.н. (см. Введение). Для слияния DADA2 нужно минимум 12 нт перекрытия, то есть $\text{trunc}_f + \text{trunc}_r \geq 303$. У нас $220 + 200 = 420$, перекрытие ≈ 129 нт: запас большой, и параметры можно было выбирать по качеству.

Всего до конца доходит 69% прочтений. Доля выживших (non-chimeric от input) ниже всего у W (56–70%, худший образец – W6) и L (62–72%), выше у LR (72–77%) и WR (66–75%). Химеры составляют небольшую часть (разница между merged и non-chimeric у большинства образцов от нуля до нескольких процентов), так что библиотека хорошего качества, а параметры обрезки подобраны корректно.

4 Классификация таксономии

Использован классификатор 2022.10.backbone.v4.nb.sklearn-1.4.2.qza (GreenGenes2, регион V4): наивный байесовский классификатор, который для каждого ASV выдаёт самый глубокий уровень таксономии с уверенностью не ниже 0.7 (значение по умолчанию). Второй классификатор (gg-13-8-99-515-806-nb-classifier.qza) не подошёл из-за несовместимости версии scikit-learn (0.24.1 против 1.4.2 в контейнере). Классификация запускалась через SLURM (партиция AMD9554, 40 ГБ, 8 ядер): на логин-узле процесс прерывался по нехватке памяти.

5 Таксономический состав (taxa barplot)

Построен qiime taxa barplot по таблице ASV и результатам классификации (Рис. 6, 7).

- **Класс (Level 3).** По составу классов дикие образцы (W/WR) разнообразнее: заметные доли *Bacteroidia*, *Campylobacteria*, *Desulfovibrionia*, *Bacilli*. У лабораторных (L/LR)

преобладает *Clostridia* (примерно 68–90% против 10–66% у диких). *Gammaproteobacteria* видны только у W (до ≈10%), у WR их почти нет.

- Род (Level 6). У диких мышей состав мозаичный, с несколькими содоминирующими родами (*Helicobacter_D*, *Parabacteroides_B*, *Dysosmobacter*, *Mucispirillum* и др.). У лабораторных всё заметнее (до ≈30% в L6 и L8) один таксон из семейства *Lachnospiraceae*, не определённый до рода.
- По составу это согласуется со статьёй: лабораторные образцы сведены к малому числу доминирующих групп (почти целиком *Clostridia*), а у диких несколько классов занимают заметную долю.




Рис. 6: Таха barplot, уровень класса (Level 3), образцы отсортированы по доле *Clostridia*.




Рис. 7: Таха barplot, уровень рода (Level 6).

6 Таблица ASV и разрежение

Итоговая таблица ASV (`qiime feature-table summarize`) содержит 516 ASV и 93 235 прочтений на 29 образцов (69% от исходных 134 672). Прочтений на образец: минимум 1392 (W1), медиана 3438, максимум 4811 (LR2); на ASV: минимум 2, медиана 47.5, максимум 4914.

Метрики разнообразия рассчитаны с `--p-sampling-depth 2000`. Разрежение нужно потому, что образец с большим числом прочтений выглядит богаче просто из-за глубины секвенирования: из каждого образца случайно берётся одинаковое число прочтений. При этом пороге образцы с меньшим числом прочтений исключаются: выпал только W1 (1392 рида), ближайший к порогу образец L5 (2065) прошёл.

Таблица 1: Таблица ASV до и после разрежения до 2000 прочтений на образец.

	до разрежения	после (<code>rarefied_table</code>)
Образцы	29	28
ASV	516	502
Всего прочтений	93 235	56 000

В анализ вошли 28 из 29 образцов: в группе W осталось 6 образцов вместо 7, в остальных $n = 8$ (L), 7 (LR) и 7 (WR). Число прочтений после разрежения равно 28×2000 .

7 Филогенетическое дерево

Дерево построено командой `qiime phylogeny align-to-tree-mafft-fasttree` (выравнивание MAFFT → маскирование → FastTree → укоренение); на его основе рассчитан `qiime diversity core-metrics-phylogenetic`.

На слайдах семинара для визуализации дерева предложен `qiime empress tree-plot` - но его запустить не удалось. Вместо этого рисунок построен с помощью скрипта на Python (matplotlib): по файлу `tree.nwk` (экспорт из QIIME 2) и таксономии `taxonomy.tsv` он рисует дерево по кругу и раскрашивает ветви и внешнее кольцо по типу (phylum).




Рис. 8: Филогенетическое дерево 516 ASV. Кольцо и ветви раскрашены по типу (phylum, GreenGenes2); тёмно-серые ветви объединяют ASV разных типов, светло-серые – редкие или не определённые типы. Длины ветвей не в масштабе.

Большинство ASV относится к двум типам: *Firmicutes_A* (377 ASV, 73%) и *Bacteroidota* (76 ASV, 15%); остальные – *Firmicutes_D* (28), *Proteobacteria* (8), *Desulfobacterota_I* (6), *Cyanobacteria* (6), *Campylobacterota* (5), *Firmicutes_B* (4), *Verrucomicrobiota* и *Deferribacterota* (по 2), ещё у 2 ASV тип не определён. Все 76 ASV *Bacteroidota* сидят на одной обособленной ветви дерева. *Firmicutes_A* в этой таксономии почти целиком (376 из 377 ASV) состоит из *Clostridia*, что согласуется с их доминированием на barplot.

8 Бета-разнообразие




Рис. 9: PCoA по weighted UniFrac, раскраска по группе (L – красный, LR – синий, W – оранжевый, WR – зелёный).




Рис. 10: PCoA по unweighted UniFrac, раскраска по группе.

- **Weighted.** Лабораторные группы (L, LR) образуют компактный кластер, дикие расположены значительно дальше. W уходит далеко вдоль Axis 1 (64.35%), WR отделена в основном вдоль Axis 2 (13.53%). Дикие образцы, особенно W, разбросаны шире лабораторных: дикая микробиота вариабельнее между особями, лабораторная однороднее, что ожидаемо для контролируемых условий содержания.

- **Unweighted.** Axis 1 (42.26%) делит образцы на два кластера: лабораторные (L, LR) слева, дикие (W, WR) справа. L и LR частично перекрываются, а W и WR разделены вдоль Axis 2 (13.77%). Картина та же, но с меньшей долей объяснённой вариации, чем у weighted.

Статистическая проверка (PERMANOVA)

Команда `qiime diversity beta-group-significance`, столбец `group`, `--p-method permanova` `--p-pairwise`, 999 перестановок, 28 образцов.

Таблица 2: PERMANOVA по группам: $\text{pseudo-}F$ и q -value (для общего теста – p).

Сравнение	weighted UniFrac		unweighted UniFrac	
	$\text{pseudo-}F$	q	$\text{pseudo-}F$	q
Все группы	21.90	$p = 0.001$	11.15	$p = 0.001$
L – LR	6.48	0.003	3.73	0.0012
L – W	27.93	0.002	11.02	0.0012
L – WR	33.97	0.002	19.73	0.0020
LR – W	25.41	0.002	11.48	0.0012
LR – WR	26.04	0.003	18.30	0.0012
W – WR	11.76	0.003	5.10	0.0012

Значимы все попарные сравнения по обоим метрикам ($q \leq 0.003$); $p = 0.001$ – минимум при 999 перестановках. Меньше всего различаются пары L–LR ($\text{pseudo-}F$ 6.48 и 3.73) и W–WR (11.76 и 5.10), больше всего – L–WR (33.97 и 19.73). Пара W–WR различается сильнее L–LR по обоим метрикам: лабораторная микробиота, пересаженная germ-free мыши, остаётся близкой к донорской, а дикая в новом хозяине воспроизводится хуже. Порядок остальных пар у метрик различается, и значения $\text{pseudo-}F$ между ними напрямую сравнивать нельзя. Кроме того, PERMANOVA не отличает сдвиг центров групп от разного разброса внутри групп, а W на PCoA заметно разбросана шире.

9 Альфа-разнообразие (индекс Шеннона)




Рис. 11: Индекс Шеннона по группам (L, LR, W, WR).

Наименьшее разнообразие в группе W (медиана по boxplot ≈ 4.8), затем L (≈ 5.2); наибольшее в LR (≈ 5.8) и WR (≈ 5.7 , с двумя выбросами).

Тест Краскела–Уоллиса (qiime diversity alpha-group-significance). По всем группам $H = 19.41$, $p = 2.2 \cdot 10^{-4}$. Попарно:

Группа 1	Группа 2	H	p	q
L	LR	9.76	0.0018	0.0081
L	W	5.40	0.0201	0.0242
L	WR	7.08	0.0078	0.0117
LR	W	9.00	0.0027	0.0081
LR	WR	0.33	0.565	0.565
W	WR	8.16	0.0043	0.0085

Значимо различаются все пары, кроме LR и WR ($q = 0.565$). Разнообразие в W значимо ниже, чем в L, а у мышей, получивших микробиоту (LR и WR), оно статистически не различается между собой ($q = 0.565$, $n = 7$ в каждой группе) и выше, чем у обоих доноров. Значит, альфа-разнообразие отражает сам факт колонизации germ-free мышей, но не то, чьё именно сообщество пересаживали. Низкое разнообразие W не противоречит большому бета-разнообразию диких мышей: в каждой особи сообщество доминируется небольшим числом таксонов (альфа), но у разных особей это разные таксоны (бета).

Общий вывод

- **Состав:** лабораторная микробиота гомогенна и доминируется классом *Clostridia* (примерно 68–90%, в основном семейство *Lachnospiraceae*); дикая гетерогенна, с несколькими содоминирующими таксонами.
- **Бета-разнообразие:** лабораторные образцы образуют компактный кластер, дикие разбросаны шире. PERMANOVA по обеим метрикам подтверждает различие всех групп (weighted $F = 21.90$, unweighted $F = 11.15$, $p = 0.001$); ближе всего донор и реципиент друг к другу (L–LR, W–WR).
- **Альфа-разнообразие:** у W оно ниже, чем у L; у LR и WR выше, чем у обоих доноров, и друг от друга они не различаются ($q = 0.565$).
- Анализ проведён на 28 из 29 образцов (W1 исключён при разрежении до 2000 прочтений).

Это согласуется с темой статьи (Rosshart et al., 2017): микробиота диких и лабораторных мышей принципиально различается и по составу, и по структуре сообщества, что имеет функциональные последствия для устойчивости хозяина к заболеваниям.