

Отчёт по домашнему заданию

QIIME2, метагеномика почвенного микробиома при загрязнении керосином (soil)

Анна Шифон

20 сентября 2026 г.

Введение

Использованы данные секвенирования гена 16S rRNA бактериального сообщества дерново-подзолистой почвы (single-end, Illumina MiSeq, регион V4–V5, праймеры 515F/907R), загрязнённой керосином: без загрязнения (k0), слабое (k5 – 5 г/кг) и сильное (k25 – 25 г/кг). Пробы отбирались в четыре момента после загрязнения: день 3 (t1), 90 (t2), 180 (t3) и 360 (t4), по три биологические реплики на каждую комбинацию доза × время, всего 36 образцов. Из-за низкого качества концов обратных прочтений (R2) анализ проведён только по прямым прочтениям (R1). Использовался QIIME2 (Singularity, образ qiime2-amplicon:2024.10) на удалённом сервере.

1 Задача 1: контроль качества сырых данных (FastQC)

FastQC запущен для образца SRR17307316_1.fastq: 10 833 рида длиной 251 п.н., GC-состав 57%, повреждённых ридов нет.

- **Качество** (Рис. 1): медианы по позициям остаются на уровне 33–38 Phred на всей длине рида. Нижние усы боксплотов с ~135 п.н. заходят в жёлтую зону, а к самому концу рида достигают красной; это обычная деградация к 3'-концу Illumina. Среднее качество по ридам имеет резкий пик около Phred 37 (примерно половина ридов).
- **Состав оснований** (Рис. 2, красный крест): в первых ~15 позициях резкие неслучайные скачки, соответствующие сайту посадки праймера 515F (5'-GTGYCAGCM GCCGCGGТАА-3'). В позициях 1–3 и 5–8 почти 100% одного основания (G, T, G, C, A, G, C), а в позициях 4 и 9 смесь (T и C, A и C): это вырожденные основания Y и M праймера. После ~15–20 п.н. состав выравнивается. Для ампликонного секвенирования это ожидаемо и не говорит о плохой библиотеке.

✓ Per base sequence quality




Рис. 1: FastQC: качество прочтений по позициям (Per base sequence quality).

✗ Per base sequence content




Рис. 2: FastQC: нуклеотидный состав по позициям (Per base sequence content).

2 Задача 2: параметр `--p-trim-left 25`

Параметр обрезает первые 25 нуклеотидов каждого прочтения, то есть праймер 515F (19 п.н.) с небольшим запасом. Праймер – искусственная последовательность, одинаковая во всех рядах независимо от бактерии. Если её не удалить, DADA2 будет учитывать

её при оценке ошибок секвенирования и в самих ASV, что исказит результат. Это подтверждает и Рис. 2: неслучайный состав оснований именно в начале рида.

3 Задача 3: статистика фильтрации DADA2

Запущена команда:

```
qiime dada2 denoise-single --p-trim-left 25 --p-trunc-len 200
--p-max-ee 3 --p-pooling-method pseudo
--p-chimera-method consensus
--p-min-fold-parent-over-abundance 4
```

sample-id	input	filtered	percentage of input passed filter	denoised	non-chimeric	percentage of input non-chimeric
SRR17307380	5128	5087	99.2	4830	4809	93.78
SRR17307593	5208	5159	99.06	4887	4866	93.43
SRR17307262	5996	5926	98.83	5754	5731	95.58
SRR17307636	6890	6812	98.87	6642	6634	96.28
SRR17307527	7624	7536	98.85	7335	7291	95.63
SRR17307643	8233	8174	99.28	7711	7705	93.59
SRR17307404	8614	8551	99.27	8158	8141	94.51
SRR17307364	8661	8605	99.35	8270	8270	95.49
SRR17307540	9247	9056	97.93	8949	8918	96.44
SRR17307436	9471	9380	99.04	9019	8993	94.95
SRR17307400	9513	9351	98.3	9127	9077	95.42
SRR17307649	9577	9502	99.22	9121	9114	95.17

Рис. 3: Статистика DADA2 по 36 образцам: input → filtered → denoised → non-chimeric.

- Исходная глубина сильно различается: от 5128 ридов (SRR17307380) до 45 492 (SRR17307475), почти в 9 раз. После всех этапов остаётся от 4809 до 43 518 ридов.
- До финала доживает 89.4–97.08% ридов (у большинства образцов 93–97%). Общие потери 3–11% невелики, что согласуется с высоким качеством по FastQC. Провальных образцов нет.
- Главная сложность – дисбаланс глубины между образцами: образец с большим числом прочтений выглядит богаче просто потому, что его прочитали глубже. Поэтому для метрик разнообразия из каждого образца случайно берётся одинаковое число прочтений: глубина 4800 (чуть ниже минимума 4809, --p-sampling-depth 4800), все 36 образцов сохраняются.

4 Задача 4: классификатор, обученный на V4

Анализ ведётся только по прямым прочтениям длиной 251 п.н., причём после --p-trim-left 25 и --p-trunc-len 200 используются позиции 26–200 (по документации DADA2 итоговая длина 200 – 25 = 175 п.н.). Поэтому реально проанализирован

5 Задача 5: визуализация таксономического состава

[illegible]

4




Рис. 5: Таха barplot, уровень рода (Level 6).

Таблица 1: Медианные доли основных классов в первой (t1) и последней (t4) временных точках, %.

Класс	k0_t1	k5_t1	k25_t1	k0_t4	k5_t4	k25_t4
Gammaproteobacteria	9.6	9.9	9.2	6.6	9.6	87.1
Acidobacteriae	18.6	17.8	18.7	48.3	46.7	1.2
Alphaproteobacteria	16.9	16.1	16.8	15.9	11.8	3.2
Actinomycetia	10.6	10.7	10.9	5.1	12.3	1.0

Похожи ли образцы в t1? Да. Во всех трёх группах сообщество гетерогенно, ни один класс не доминирует: *Acidobacteriae* (17.8–18.7%), *Alphaproteobacteria* (16.1–16.9%), *Actinomycetia* (10.6–10.9%), *Gammaproteobacteria* (9.2–9.9%). Различия между дозами не превышают нескольких процентных пунктов, что согласуется с общим кластером t1 на PCoA (Рис. 8).

Как меняется состав со временем?

- **k0:** умеренный дрейф: *Acidobacteriae* растут с 18.6 до 48.3%, *Gammaproteobacteria* снижаются с 9.6 до 6.6%; разнообразие остаётся высоким (Шеннон на t4 – 8.27).
- **k5:** *Gammaproteobacteria* растут с 9.9% (t1) до 30.2% (t2) и 46.6% (t3), а к t4 возвращаются к 9.6%; *Acidobacteriae* после 26.0% (t2) и 19.7% (t3) достигают 46.7% на t4.
- **k25:** наиболее выраженная направленная динамика: *Gammaproteobacteria* 9.2 → 32.4 → 61.8 → 87.1%, *Acidobacteriae* 18.7 → 19.1 → 6.0 → 1.2%.

Самые частые классы. В t1 – сопоставимые доли *Acidobacteriae*, *Alphaproteobacteria*, *Actinomycetia* и *Gammaproteobacteria*. В t4 в k0 и k5 лидируют *Acidobacteriae* (48.3 и 46.7%), а в k25 абсолютно доминируют *Gammaproteobacteria* (87.1%): на остальные классы вместе приходится меньше 13%.

Самый частый род в загрязнённых образцах (Level 6). Это *Paraburkholderia* (класс *Gammaproteobacteria*, порядок *Burkholderiales*); именно он даёт доминирование *Gammaproteobacteria* в k25_t4.

Таблица 2: Медианные доли трёх заметных родов, %.

Род	k0_t1	k0_t4	k5_t2	k5_t3	k5_t4	k25_t2	k25_t3	k25_t4
<i>Paraburkholderia</i>	0.3	0.2	14.9	26.1	5.9	27.3	53.7	84.2
<i>Acidoferrum</i>	4.8	12.3	10.4	9.3	24.5	5.7	1.2	0.2
<i>Nevskia</i>	0.0	0.0	6.3	8.8	0.7	0.0	2.1	0.0

В контроле *Paraburkholderia* практически отсутствует (0.2–0.3%). В k25 она растёт до 84.2% в t4 (по репликам 78.6, 84.2 и 88.0%), то есть 87.1% *Gammaproteobacteria* состоят почти целиком из неё. В k5 она достигает 26.1% к t3 и падает до 5.9% к t4.

Ожидаемо ли это при загрязнении керосином? Да: *Burkholderiales* и *Paraburkholderia* – классические почвенные деструкторы углеводов, использующие компоненты керосина как источник углерода и энергии, поэтому их доля растёт именно в загрязнённых образцах и со временем. Ацидобактерии рода *Acidoferrum* ведут себя противоположно: в k25 вытесняются (5.5% на t1 → 0.2% на t4), в k0 растут (4.8 → 12.3%), в k5 на t4 достигают 24.5%.

6 Задача 6 и 7: филогенетическое дерево и метрики разнообразия

Построено дерево (qiime phylogeny align-to-tree-mafft-fasttree: выравнивание MAFFT → маскирование → FastTree → укоренение). На его основе рассчитаны метрики альфа- и бета-разнообразия (qiime diversity core-metrics-phylogenetic с --p-sampling-depth 4800).

Визуализировать дерево в MEGA у меня не получилось, поэтому рисунок построила с помощью ИИ: по файлу `tree.nwk` (экспорт из QIIME 2) и таксономии `taxonomy.tsv` он написал скрипт на Python (matplotlib), который рисует дерево по кругу и раскрашивает ветви и кольцо по типу (phylum).




Рис. 6: Филогенетическое дерево 1944 ASV. Кольцо и ветви раскрашены по типу (phylum, GreenGenes2); тёмно-серые ветви объединяют ASV разных типов, светло-серые – редкие или не определённые типы. Длины ветвей не в масштабе.

6.1 Задача 6: бета-разнообразие




Рис. 7: PCoA по weighted UniFrac, раскраска по contamination_level (k0 – красный, k5 – оранжевый, k25 – синий).




Рис. 8: PCoA по weighted UniFrac, раскраска по `level_and_time_point` (12 групп: уровень загрязнения $\times$ время).

- **Оси.** Axis 1 (56.53%) – главная: вдоль неё k0 занимает область высоких значений (справа), k25 – низких (слева), k5 между ними. Axis 2 (24.66%) отражает в основном смену во времени: у k0 и k5 более поздние точки лежат выше. Axis 3 (7.09%) вносит заметно меньший вклад.
- **Первая точка (t1).** k0_t1, k5_t1 и k25_t1 образуют один тесный смешанный кластер: на день 3 сообщество ещё не отреагировало на керосин.
- **Динамика.** k0_t2–t4 смещаются вправо вверх и остаются там компактно. Загрязнённые образцы отдаляются от контроля вдоль Axis 1: точка k25_t4 самая левая, то есть максимально удалена от контроля. k5_t2 и k5_t3 смещаются влево, но не так далеко, как k25.
- **Восстановление.** Для k25 его нет: k25_t4 дальше от контроля, чем k25_t3. Для k5 результат неоднозначный: k5_t4 по Axis 1 правее k5_t3, а состав вернулся к контрольному по главному классу (*Acidobacteriae* 46.7% против 48.3% в k0_t4; *Gammaproteobacteria* 46.6 $\rightarrow$ 9.6%; *Paraburkholderia* 26.1 $\rightarrow$ 5.9%). Но k5_t4 остаётся отдельной группой, сдвинутой вверх по Axis 2, а *Paraburkholderia* всё ещё в 30 раз выше, чем в контроле (5.9% против 0.2%). Корректно говорить о частичном восстановлении состава, а не о полном возврате к контролю за 360 дней.




Рис. 9: PCoA по unweighted UniFrac, раскраска по `contamination_level` (k0 – красный, k5 – оранжевый, k25 – синий). Оси: 35.64%, 12.81%, 6.49%.

Unweighted UniFrac учитывает только присутствие или отсутствие филогенетических ветвей, weighted – ещё и их обилие. По unweighted оси объясняют меньше вариации (35.64% и 12.81% против 56.53% и 24.66%), и группы разделяются хуже.

Статистическая проверка: PERMANOVA

Команда `qiime diversity beta-group-significance`, столбец `contamination_level`, `--p-method permanova` `--p-pairwise`, 999 перестановок, 36 образцов.

Таблица 3: PERMANOVA по уровню загрязнения: pseudo- F и q -value (для общего теста – p).

Сравнение	weighted UniFrac		unweighted UniFrac	
	pseudo- F	q	pseudo- F	q
Все группы	8.00	$p = 0.001$	2.51	$p = 0.006$
k0 – k25	14.08	0.0030	3.26	0.0165
k0 – k5	6.06	0.0045	3.27	0.0165
k5 – k25	4.68	0.0100	1.22	0.231

По weighted UniFrac значимо различаются все три пары: сильнее всего k0 и k25, слабее всего k5 и k25. По unweighted и k5, и k25 значимо отличаются от контроля, причём сопоставимо, а друг от друга не отличаются ($q = 0.231$). Значит, основная разница между дозами – в относительном обилии таксонов, а не в наборе присутствующих линий: керосин прежде всего меняет пропорции. Например, доля *Acidobacteriae* в k25 падает с 18.7% до 1.2%, но они не исчезают. Значения pseudo- F двух метрик строго сравнивать нельзя, однако разрыв (8.00 против 2.51) согласуется с этим выводом. Оговорка: тест применён ко всем четырём временным точкам сразу, а на t1 сообщества всех доз почти одинаковы, поэтому различия между дозами занижены по сравнению с поздними точками.

6.2 Задача 7: альфа-разнообразие (индекс Шеннона)

Alpha Diversity Boxplots




Рис. 10: Индекс Шеннона по уровням загрязнения ($n = 12$ в каждой группе).

Медианы по уровням (усреднение по времени): k0 – 8.76 (самое высокое и стабильное разнообразие), k5 – 7.30, k25 – 7.00 (самый широкий разброс, нижний ус почти до 2.6). Медианы по группам доза $\times$ время (по 3 реплики):

Доза	t1 (день 3)	t2 (день 90)	t3 (день 180)	t4 (день 360)
k0	9.01	8.92	8.67	8.27
k5	9.03	7.83	6.68	6.84
k25	8.90	7.60	5.69	2.97

В контроле разнообразие медленно снижается. В k5 оно падает до 6.68 к дню 180 и слегка растёт (6.84 на t4), но этот рост укладывается в разброс реплик и не подтверждён статистически. В k25 разнообразие падает на каждом шаге и к t4 втрое ниже, чем в начале: сообщество схлопнулось до нескольких доминантов (*Paraburkholderia*).

Тест Краскела–Уоллиса (qiime diversity alpha-group-significance):

Группировка	H	p
contamination_level	9.83	0.0073
day_after_contamination	21.71	$7.5 \cdot 10^{-5}$
level_and_time_point	34.13	$3.4 \cdot 10^{-4}$
replica_number	0.00	1.0

- **По уровню загрязнения:** k0 против k25 – $q = 0.0168$, k0 против k5 – $q = 0.0365$ (значимо после поправки); k25 против k5 – $q = 0.149$ (не значимо).
- **По времени:** день 3 значимо отличается от всех остальных точек ($q = 0.001$ – 0.003), а d90, d180 и d360 между собой не различаются ($q \geq 0.056$): основной провал разнообразия происходит в первые три месяца.

- **По доза × время:** из 66 попарных сравнений после поправки ни одно не значимо (минимальное $q = 0.055$): в каждой группе всего по три образца, а при 3 против 3 наименьшее достижимое p у теста Краскела–Уоллиса равно 0.0495. Различия между конкретными комбинациями (например, k5 и k25 на t4: 6.84 и 2.97) видны по медианам, но статистически не подтверждаются.

Интерпретация. Загрязнение керосином, и слабое, и сильное, значимо снижает альфа-разнообразие относительно контроля. Отсутствие значимого различия между k5 и k25 при усреднении по времени не означает насыщения эффекта дозы: на t1 все дозы одинаковы, а к t4 разнообразие в k25 (2.97) втрое ниже, чем в k5 (6.84); усреднение по четырём точкам смазывает эту разницу. Широкий разброс внутри загрязнённых групп объясняется временной динамикой: ранние точки близки к контролю, поздние (особенно k25_t4) намного ниже из-за доминирования одного таксона (*Paraburkholderia*).

Общий вывод

- **Таксономия:** в t1 все три группы близки и гетерогенны. В загрязнённых образцах со временем растёт доля деструкторов углеводов: в k25_t4 *Gammaproteobacteria* составляют 87.1%, почти целиком за счёт *Paraburkholderia* (84.2%). В k5 она достигает максимума 26.1% на t3 и падает до 5.9% к t4. Контроль меняется умеренно и сохраняет разнообразие.
- **Бета-разнообразие:** в t1 сообщества всех доз близки, затем загрязнённые расходятся с контролем вдоль Axis 1 (56.53%). PERMANOVA по weighted UniFrac подтверждает различие всех пар ($F = 8.00$, $p = 0.001$); по unweighted различия слабее ($F = 2.51$), k5 и k25 друг от друга не отличаются: керосин меняет главным образом пропорции таксонов.
- **Альфа-разнообразие:** и слабое, и сильное загрязнение значимо снижают индекс Шеннона относительно контроля; между k5 и k25 при усреднении по времени значимой разницы нет, но на t4 она велика (6.84 против 2.97).
- **Восстановление:** для k25 за 360 дней его нет ни по одному показателю. Для k5 есть частичное восстановление состава (лидируют *Acidobacteriae*, как в контроле; спад *Paraburkholderia*), но по Шеннону (6.84 против 8.27) и положению на PCoA сообщество к контролю не вернулось, а рост Шеннона между t3 и t4 не подтверждён.

Эти наблюдения согласуются с темой семинара (Rosshart et al., 2017): состав и структура микробного сообщества не статичны, а динамично реагируют на внешние воздействия, и изменения могут сохраняться длительное время и иметь функциональные последствия.