

# Отчёт по домашнему заданию

## QIIME2, метагеномика почвенного микробиома при загрязнении керосином (soil)

Анна Шифон

20 сентября 2026 г.

### Введение

Использованы данные секвенирования гена 16S rRNA бактериального сообщества дерново-подзолистой почвы (single-end, Illumina MiSeq, регион V4–V5, праймеры 515F/907R), загрязнённой керосином: без загрязнения (k0), слабое (k5 – 5 г/кг) и сильное (k25 – 25 г/кг). Пробы отбирались в четыре момента после загрязнения: день 3 (t1), 90 (t2), 180 (t3) и 360 (t4), по три биологические реплики на каждую комбинацию доза × время, всего 36 образцов. Из-за низкого качества концов обратных прочтений (R2) анализ проведён только по прямым прочтениям (R1). Использовался QIIME2 (Singularity, образ qiime2-amplicon:2024.10) на удалённом сервере.

### 1 Задача 1: контроль качества сырых данных (FastQC)

FastQC запущен для образца SRR17307316\_1.fastq: 10 833 рида длиной 251 п.н., GC-состав 57%, повреждённых ридов нет.

- **Качество** (Рис. 1): медианы по позициям остаются на уровне 33–38 Phred на всей длине рида. Нижние усы боксплотов с ~135 п.н. заходят в жёлтую зону, а к самому концу рида достигают красной; это обычная деградация к 3'-концу Illumina. Среднее качество по ридам имеет резкий пик около Phred 37 (примерно половина ридов).
- **Состав оснований** (Рис. 2, красный крест): в первых ~15 позициях резкие неслучайные скачки, соответствующие сайту посадки праймера 515F (5'-GTGYCAGCM GCCGCGGТАА-3'). В позициях 1–3 и 5–8 почти 100% одного основания (G, T, G, C, A, G, C), а в позициях 4 и 9 смесь (T и C, A и C): это вырожденные основания Y и M праймера. После ~15–20 п.н. состав выравнивается. Для ампликонного секвенирования это ожидаемо и не говорит о плохой библиотеке.

### ✔ Per base sequence quality




Рис. 1: FastQC: качество прочтений по позициям (Per base sequence quality).

### ✖ Per base sequence content




Рис. 2: FastQC: нуклеотидный состав по позициям (Per base sequence content).

## 2 Задача 2: параметр `--p-trim-left 25`

Параметр обрезает первые 25 нуклеотидов каждого прочтения, то есть праймер 515F (19 п.н.) с небольшим запасом. Праймер – искусственная последовательность, одинаковая во всех рядах независимо от бактерии. Если её не удалить, DADA2 будет учитывать

её при оценке ошибок секвенирования и в самих ASV, что исказит результат. Это подтверждает и Рис. 2: неслучайный состав оснований именно в начале рида.

### 3 Задача 3: статистика фильтрации DADA2

Запущена команда:

```
qiime dada2 denoise-single --p-trim-left 25 --p-trunc-len 200
--p-max-ee 3 --p-pooling-method pseudo
--p-chimera-method consensus
--p-min-fold-parent-over-abundance 4
```

| sample-id   | input | filtered | percentage of input passed filter | denoised | non-chimeric | percentage of input non-chimeric |
|-------------|-------|----------|-----------------------------------|----------|--------------|----------------------------------|
| SRR17307380 | 5128  | 5087     | 99.2                              | 4830     | 4809         | 93.78                            |
| SRR17307593 | 5208  | 5159     | 99.06                             | 4887     | 4866         | 93.43                            |
| SRR17307262 | 5996  | 5926     | 98.83                             | 5754     | 5731         | 95.58                            |
| SRR17307636 | 6890  | 6812     | 98.87                             | 6642     | 6634         | 96.28                            |
| SRR17307527 | 7624  | 7536     | 98.85                             | 7335     | 7291         | 95.63                            |
| SRR17307643 | 8233  | 8174     | 99.28                             | 7711     | 7705         | 93.59                            |
| SRR17307404 | 8614  | 8551     | 99.27                             | 8158     | 8141         | 94.51                            |
| SRR17307364 | 8661  | 8605     | 99.35                             | 8270     | 8270         | 95.49                            |
| SRR17307540 | 9247  | 9056     | 97.93                             | 8949     | 8918         | 96.44                            |
| SRR17307436 | 9471  | 9380     | 99.04                             | 9019     | 8993         | 94.95                            |
| SRR17307400 | 9513  | 9351     | 98.3                              | 9127     | 9077         | 95.42                            |
| SRR17307649 | 9577  | 9502     | 99.22                             | 9121     | 9114         | 95.17                            |

Рис. 3: Статистика DADA2 по 36 образцам: input → filtered → denoised → non-chimeric.

- Исходная глубина сильно различается: от 5128 ридов (SRR17307380) до 45 492 (SRR17307475), почти в 9 раз. После всех этапов остаётся от 4809 до 43 518 ридов.
- До финала доживает 89.4–97.08% ридов (у большинства образцов 93–97%). Общие потери 3–11% невелики, что согласуется с высоким качеством по FastQC. Провальных образцов нет.
- Главная сложность – дисбаланс глубины между образцами: образец с большим числом прочтений выглядит богаче просто потому, что его прочитали глубже. Поэтому для метрик разнообразия из каждого образца случайно берётся одинаковое число прочтений: глубина 4800 (чуть ниже минимума 4809, --p-sampling-depth 4800), все 36 образцов сохраняются.

### 4 Задача 4: классификатор, обученный на V4

Анализ ведётся только по прямым прочтениям длиной 251 п.н., причём после --p-trim-left 25 и --p-trunc-len 200 используются позиции 26–200 (по документации DADA2 итоговая длина 200 – 25 = 175 п.н.). Поэтому реально проанализирован

регион V4, а не весь V4–V5: V5 лежит дальше по ампликону и покрывался бы только R2. Значит, классификатор, обученный на V4 (2022.10.backbone.v4.nb.sklearn-1.4.2.qza, GreenGenes2), соответствует фактически использованной части гена. Классификация запускалась через SLURM (партиция AMD9554, 40 ГБ, 8 ядер): на логин-узле процесс прерывался по нехватке памяти.

## 5 Задача 5: визуализация таксономического состава

Построен qiime taxa barplot, образцы отсортированы по level\_and\_time\_point. Точные доли взяты из CSV barplot (Level 3 и Level 6); везде ниже – медианы по трём репликам, %.




Рис. 4: Taxa barplot, уровень класса (Level 3).




Рис. 5: Таха barplot, уровень рода (Level 6).

Таблица 1: Медианные доли основных классов в первой (t1) и последней (t4) временных точках, %.

| Класс               | k0_t1 | k5_t1 | k25_t1 | k0_t4 | k5_t4 | k25_t4      |
|---------------------|-------|-------|--------|-------|-------|-------------|
| Gammaproteobacteria | 9.6   | 9.9   | 9.2    | 6.6   | 9.6   | <b>87.1</b> |
| Acidobacteriae      | 18.6  | 17.8  | 18.7   | 48.3  | 46.7  | 1.2         |
| Alphaproteobacteria | 16.9  | 16.1  | 16.8   | 15.9  | 11.8  | 3.2         |
| Actinomycetia       | 10.6  | 10.7  | 10.9   | 5.1   | 12.3  | 1.0         |

**Похожи ли образцы в t1?** Да. Во всех трёх группах сообщество гетерогенно, ни один класс не доминирует: *Acidobacteriae* (17.8–18.7%), *Alphaproteobacteria* (16.1–16.9%), *Actinomycetia* (10.6–10.9%), *Gammaproteobacteria* (9.2–9.9%). Различия между дозами не превышают нескольких процентных пунктов, что согласуется с общим кластером t1 на PCoA (Рис. 8).

**Как меняется состав со временем?**

- **k0:** умеренный дрейф: *Acidobacteriae* растут с 18.6 до 48.3%, *Gammaproteobacteria* снижаются с 9.6 до 6.6%; разнообразие остаётся высоким (Шеннон на t4 – 8.27).
- **k5:** *Gammaproteobacteria* растут с 9.9% (t1) до 30.2% (t2) и 46.6% (t3), а к t4 возвращаются к 9.6%; *Acidobacteriae* после 26.0% (t2) и 19.7% (t3) достигают 46.7% на t4.
- **k25:** наиболее выраженная направленная динамика: *Gammaproteobacteria* 9.2 → 32.4 → 61.8 → 87.1%, *Acidobacteriae* 18.7 → 19.1 → 6.0 → 1.2%.

**Самые частые классы.** В t1 – сопоставимые доли *Acidobacteriae*, *Alphaproteobacteria*, *Actinomycetia* и *Gammaproteobacteria*. В t4 в k0 и k5 лидируют *Acidobacteriae* (48.3 и 46.7%), а в k25 абсолютно доминируют *Gammaproteobacteria* (87.1%): на остальные классы вместе приходится меньше 13%.

Самый частый род в загрязнённых образцах (Level 6). Это *Paraburkholderia* (класс *Gammaproteobacteria*, порядок *Burkholderiales*); именно он даёт доминирование *Gammaproteobacteria* в k25\_t4.

Таблица 2: Медианные доли трёх заметных родов, %.

| Род                     | k0_t1 | k0_t4 | k5_t2 | k5_t3 | k5_t4 | k25_t2 | k25_t3 | k25_t4      |
|-------------------------|-------|-------|-------|-------|-------|--------|--------|-------------|
| <i>Paraburkholderia</i> | 0.3   | 0.2   | 14.9  | 26.1  | 5.9   | 27.3   | 53.7   | <b>84.2</b> |
| <i>Acidoferrum</i>      | 4.8   | 12.3  | 10.4  | 9.3   | 24.5  | 5.7    | 1.2    | 0.2         |
| <i>Nevskia</i>          | 0.0   | 0.0   | 6.3   | 8.8   | 0.7   | 0.0    | 2.1    | 0.0         |

В контроле *Paraburkholderia* практически отсутствует (0.2–0.3%). В k25 она растёт до 84.2% в t4 (по репликам 78.6, 84.2 и 88.0%), то есть 87.1% *Gammaproteobacteria* состоят почти целиком из неё. В k5 она достигает 26.1% к t3 и падает до 5.9% к t4.

**Ожидаемо ли это при загрязнении керосином?** Да: *Burkholderiales* и *Paraburkholderia* – классические почвенные деструкторы углеводов, использующие компоненты керосина как источник углерода и энергии, поэтому их доля растёт именно в загрязнённых образцах и со временем. Ацидобактерии рода *Acidoferrum* ведут себя противоположно: в k25 вытесняются (5.5% на t1 → 0.2% на t4), в k0 растут (4.8 → 12.3%), в k5 на t4 достигают 24.5%.

## 6 Задача 6 и 7: филогенетическое дерево и метрики разнообразия

Построено дерево (qiime phylogeny align-to-tree-mafft-fasttree: выравнивание MAFFT → маскирование → FastTree → укоренение). На его основе рассчитаны метрики альфа- и бета-разнообразия (qiime diversity core-metrics-phylogenetic с --p-sampling-depth 4800).

Визуализировать дерево в MEGA у меня не получилось, поэтому рисунок построила с помощью ИИ: по файлу `tree.nwk` (экспорт из QIIME 2) и таксономии `taxonomy.tsv` он написал скрипт на Python (matplotlib), который рисует дерево по кругу и раскрашивает ветви и кольцо по типу (phylum).




Рис. 6: Филогенетическое дерево 1944 ASV. Кольцо и ветви раскрашены по типу (phylum, GreenGenes2); тёмно-серые ветви объединяют ASV разных типов, светло-серые – редкие или не определённые типы. Длины ветвей не в масштабе.

## 6.1 Задача 6: бета-разнообразие




Рис. 7: PCoA по weighted UniFrac, раскраска по contamination\_level (k0 – красный, k5 – оранжевый, k25 – синий).




Рис. 8: PCoA по weighted UniFrac, раскраска по `level_and_time_point` (12 групп: уровень загрязнения  $\times$  время).

- **Оси.** Axis 1 (56.53%) – главная: вдоль неё k0 занимает область высоких значений (справа), k25 – низких (слева), k5 между ними. Axis 2 (24.66%) отражает в основном смену во времени: у k0 и k5 более поздние точки лежат выше. Axis 3 (7.09%) вносит заметно меньший вклад.
- **Первая точка (t1).** k0\_t1, k5\_t1 и k25\_t1 образуют один тесный смешанный кластер: на день 3 сообщество ещё не отреагировало на керосин.
- **Динамика.** k0\_t2–t4 смещаются вправо вверх и остаются там компактно. Загрязнённые образцы отдаляются от контроля вдоль Axis 1: точка k25\_t4 самая левая, то есть максимально удалена от контроля. k5\_t2 и k5\_t3 смещаются влево, но не так далеко, как k25.
- **Восстановление.** Для k25 его нет: k25\_t4 дальше от контроля, чем k25\_t3. Для k5 результат неоднозначный: k5\_t4 по Axis 1 правее k5\_t3, а состав вернулся к контрольному по главному классу (*Acidobacteriae* 46.7% против 48.3% в k0\_t4; *Gammaproteobacteria* 46.6  $\rightarrow$  9.6%; *Paraburkholderia* 26.1  $\rightarrow$  5.9%). Но k5\_t4 остаётся отдельной группой, сдвинутой вверх по Axis 2, а *Paraburkholderia* всё ещё в 30 раз выше, чем в контроле (5.9% против 0.2%). Корректно говорить о частичном восстановлении состава, а не о полном возврате к контролю за 360 дней.




Рис. 9: PCoA по unweighted UniFrac, раскраска по `contamination_level` (k0 – красный, k5 – оранжевый, k25 – синий). Оси: 35.64%, 12.81%, 6.49%.

Unweighted UniFrac учитывает только присутствие или отсутствие филогенетических ветвей, weighted – ещё и их обилие. По unweighted оси объясняют меньше вариации (35.64% и 12.81% против 56.53% и 24.66%), и группы разделяются хуже.

### Статистическая проверка: PERMANOVA

Команда `qiime diversity beta-group-significance`, столбец `contamination_level`, `--p-method permanova` `--p-pairwise`, 999 перестановок, 36 образцов.

Таблица 3: PERMANOVA по уровню загрязнения: pseudo- $F$  и  $q$ -value (для общего теста –  $p$ ).

| Сравнение  | weighted UniFrac |             | unweighted UniFrac |             |
|------------|------------------|-------------|--------------------|-------------|
|            | pseudo- $F$      | $q$         | pseudo- $F$        | $q$         |
| Все группы | 8.00             | $p = 0.001$ | 2.51               | $p = 0.006$ |
| k0 – k25   | 14.08            | 0.0030      | 3.26               | 0.0165      |
| k0 – k5    | 6.06             | 0.0045      | 3.27               | 0.0165      |
| k5 – k25   | 4.68             | 0.0100      | 1.22               | 0.231       |

По weighted UniFrac значимо различаются все три пары: сильнее всего k0 и k25, слабее всего k5 и k25. По unweighted и k5, и k25 значимо отличаются от контроля, причём сопоставимо, а друг от друга не отличаются ( $q = 0.231$ ). Значит, основная разница между дозами – в относительном обилии таксонов, а не в наборе присутствующих линий: керосин прежде всего меняет пропорции. Например, доля *Acidobacteriae* в k25 падает с 18.7% до 1.2%, но они не исчезают. Значения pseudo- $F$  двух метрик строго сравнивать нельзя, однако разрыв (8.00 против 2.51) согласуется с этим выводом. Оговорка: тест применён ко всем четырём временным точкам сразу, а на t1 сообщества всех доз почти одинаковы, поэтому различия между дозами занижены по сравнению с поздними точками.

## 6.2 Задача 7: альфа-разнообразие (индекс Шеннона)

### Alpha Diversity Boxplots




Рис. 10: Индекс Шеннона по уровням загрязнения ( $n = 12$  в каждой группе).

Медианы по уровням (усреднение по времени): k0 – 8.76 (самое высокое и стабильное разнообразие), k5 – 7.30, k25 – 7.00 (самый широкий разброс, нижний ус почти до 2.6). Медианы по группам доза  $\times$  время (по 3 реплики):

| Доза | t1 (день 3) | t2 (день 90) | t3 (день 180) | t4 (день 360) |
|------|-------------|--------------|---------------|---------------|
| k0   | 9.01        | 8.92         | 8.67          | 8.27          |
| k5   | 9.03        | 7.83         | 6.68          | 6.84          |
| k25  | 8.90        | 7.60         | 5.69          | <b>2.97</b>   |

В контроле разнообразие медленно снижается. В k5 оно падает до 6.68 к дню 180 и слегка растёт (6.84 на t4), но этот рост укладывается в разброс реплик и не подтверждён статистически. В k25 разнообразие падает на каждом шаге и к t4 втрое ниже, чем в начале: сообщество схлопнулось до нескольких доминантов (*Paraburkholderia*).

**Тест Краскела–Уоллиса** (qiime diversity alpha-group-significance):

| Группировка             | $H$   | $p$                 |
|-------------------------|-------|---------------------|
| contamination_level     | 9.83  | 0.0073              |
| day_after_contamination | 21.71 | $7.5 \cdot 10^{-5}$ |
| level_and_time_point    | 34.13 | $3.4 \cdot 10^{-4}$ |
| replica_number          | 0.00  | 1.0                 |

- **По уровню загрязнения:** k0 против k25 –  $q = 0.0168$ , k0 против k5 –  $q = 0.0365$  (значимо после поправки); k25 против k5 –  $q = 0.149$  (не значимо).
- **По времени:** день 3 значимо отличается от всех остальных точек ( $q = 0.001$ – $0.003$ ), а d90, d180 и d360 между собой не различаются ( $q \geq 0.056$ ): основной провал разнообразия происходит в первые три месяца.

- **По доза × время:** из 66 попарных сравнений после поправки ни одно не значимо (минимальное  $q = 0.055$ ): в каждой группе всего по три образца, а при 3 против 3 наименьшее достижимое  $p$  у теста Краскела–Уоллиса равно 0.0495. Различия между конкретными комбинациями (например, k5 и k25 на t4: 6.84 и 2.97) видны по медианам, но статистически не подтверждаются.

**Интерпретация.** Загрязнение керосином, и слабое, и сильное, значимо снижает альфа-разнообразие относительно контроля. Отсутствие значимого различия между k5 и k25 при усреднении по времени не означает насыщения эффекта дозы: на t1 все дозы одинаковы, а к t4 разнообразие в k25 (2.97) втрое ниже, чем в k5 (6.84); усреднение по четырём точкам смазывает эту разницу. Широкий разброс внутри загрязнённых групп объясняется временной динамикой: ранние точки близки к контролю, поздние (особенно k25\_t4) намного ниже из-за доминирования одного таксона (*Paraburkholderia*).

## Общий вывод

- **Таксономия:** в t1 все три группы близки и гетерогенны. В загрязнённых образцах со временем растёт доля деструкторов углеводов: в k25\_t4 *Gammaproteobacteria* составляют 87.1%, почти целиком за счёт *Paraburkholderia* (84.2%). В k5 она достигает максимума 26.1% на t3 и падает до 5.9% к t4. Контроль меняется умеренно и сохраняет разнообразие.
- **Бета-разнообразие:** в t1 сообщества всех доз близки, затем загрязнённые расходятся с контролем вдоль Axis 1 (56.53%). PERMANOVA по weighted UniFrac подтверждает различие всех пар ( $F = 8.00$ ,  $p = 0.001$ ); по unweighted различия слабее ( $F = 2.51$ ), k5 и k25 друг от друга не отличаются: керосин меняет главным образом пропорции таксонов.
- **Альфа-разнообразие:** и слабое, и сильное загрязнение значимо снижают индекс Шеннона относительно контроля; между k5 и k25 при усреднении по времени значимой разницы нет, но на t4 она велика (6.84 против 2.97).
- **Восстановление:** для k25 за 360 дней его нет ни по одному показателю. Для k5 есть частичное восстановление состава (лидируют *Acidobacteriae*, как в контроле; спад *Paraburkholderia*), но по Шеннону (6.84 против 8.27) и положению на PCoA сообщество к контролю не вернулось, а рост Шеннона между t3 и t4 не подтверждён.

Эти наблюдения согласуются с темой семинара (Rosshart et al., 2017): состав и структура микробного сообщества не статичны, а динамично реагируют на внешние воздействия, и изменения могут сохраняться длительное время и иметь функциональные последствия.