

Отчёт по домашнему заданию

QIIME2, метагеномика почвенного микробиома при загрязнении керосином (soil)

Анна Шифон

22 сентября 2026 г.

Введение

Использованы данные секвенирования гена 16S rRNA бактериального сообщества дерново-подзолистой почвы (single-end, Illumina MiSeq, регион V4–V5, праймеры 515F/907R), загрязнённой керосином: без загрязнения (k0), слабое (k5 – 5 г/кг) и сильное (k25 – 25 г/кг). Пробы отбирались в четыре момента после загрязнения: день 3 (t1), 90 (t2), 180 (t3) и 360 (t4), по три образца на каждую комбинацию доза × время, всего 36 образцов. Из-за низкого качества концов обратных прочтений (R2) анализ проведён только по прямым прочтениям (R1). Использовался QIIME2 (Singularity, образ qiime2-amplicon:2024.10) на удалённом сервере.

1 Задача 1: контроль качества сырых данных (FastQC)

FastQC запущен для образца SRR17307316_1.fastq (контроль k0, день 3): 10 833 ряда длиной 251 п.н., GC-состав 57%, повреждённых ридов нет. Итоговые статусы модулей FastQC:

Статус	Модули
PASS	Basic Statistics, Per base sequence quality, Per sequence quality scores, Per base N content, Sequence Length Distribution, Adapter Content
WARN	Per sequence GC content
FAIL	Per base sequence content, Sequence Duplication Levels, Overrepresented sequences

Все предупреждения ожидаемы для ампликонных данных и не указывают на проблемы библиотеки:

- **Качество** (Рис. 1, PASS): медианы по позициям остаются на уровне 33–38 Phred на всей длине рида. Нижние усы боксплотов с ~135 п.н. заходят в жёлтую зону, а к самому концу рида достигают красной; это обычная деградация к 3'-концу Illumina. Среднее качество по ридам имеет резкий пик около Phred 37 (примерно половина ридов).
- **Состав оснований** (Рис. 2, FAIL): в первых ~15 позициях резкие неслучайные скачки – это последовательность праймера 515F, одинаковая (с точностью до вырожденных позиций) во всех ридах. В позициях 1–3 и 5–8 почти 100% одного основания (G,

T, G, C, A, G, C), а в позициях 4 и 9 – смесь (Т/С и А/С соответственно). В задании праймер 515F записан как 5'-GTGCCAGCMGCCGCGGTAA-3' (вырождена только позиция 9, М); наблюдаемая смесь в позиции 4 соответствует варианту 515F-Y (5'-GTGYCAGCMGCCGCGGTAA-3', вырождены Y и М), то есть, по-видимому, фактически использованному праймеру. После ~15–20 п.н. состав выравнивается.

- **Sequence Duplication Levels (FAIL):** все риды являются копиями одного участка 16S, и прочтения от клеток одного таксона идентичны, поэтому доля дубликатов закономерно высока.
- **Overrepresented sequences (FAIL):** по той же причине последовательности самых обильных таксонов превышают порог FastQC (0.1% ридов).
- **Per sequence GC content (WARN):** FastQC ожидает нормальное распределение GC, характерное для геномной библиотеки, а в ампликонной библиотеке смесь дискретных вариантов 16S разных таксонов со своим GC-составом даёт распределение неправильной формы.
- **Adapter Content (PASS):** адаптеры в риде не обнаружены, дополнительная обрезка не нужна.




Рис. 1: FastQC: качество прочтений по позициям (Per base sequence quality).




Рис. 2: FastQC: нуклеотидный состав по позициям (Per base sequence content).

2 Задача 2: параметр `--p-trim-left 25`

Параметр обрезает первые 25 нуклеотидов каждого прочтения, то есть праймер 515F (19 п.н.) с запасом. Удалять его нужно по двум причинам.

1. **Праймер не несёт информации о бактерии.** Эта часть рида соответствует последовательности праймера, а не матрицы: при посадке праймера с мисматчами в ПЦР-продукт встраивается праймер, и реальные основания бактерии в этом участке теряются.
2. **Праймер вырожденный.** По Рис. 2 в позициях 4 и 9 наблюдается смесь оснований (Y и M). Если праймер не удалить, одна и та же бактериальная последовательность даст несколько «разных» вариантов, отличающихся только этими позициями. DADA2 может принять их за самостоятельные ASV, что искусственно завысит разнообразие.

Запас в 6 нт перекрывает возможные сдвиги начала рида и начальные позиции с пониженным качеством (Phred ≈ 33 в позициях 1–5, Рис. 1).

3 Задача 3: статистика фильтрации DADA2

Запущена команда:

```
qiime dada2 denoise-single --p-trim-left 25 --p-trunc-len 200
--p-max-ee 3 --p-pooling-method pseudo
--p-chimera-method consensus
--p-min-fold-parent-over-abundance 4
```

QIIME2view

File: soil_reads.dada2.stats.qzv

Visualization

Citations

Provenance

Metadata

Download metadata TSV file

This file won't necessarily reflect dynamic sorting or filtering options based on the interactive table below.

Search:

sample-id	input	filtered	percentage of input passed filter	denoised	non-chimeric	percentage of input non-chimeric
#q2:types	numeric	numeric	numeric	numeric	numeric	numeric
SRR17307380	5128	5087	99.2	4830	4809	93.78
SRR17307593	5208	5159	99.06	4887	4866	93.43
SRR17307262	5996	5926	98.83	5754	5731	95.58
SRR17307636	6890	6812	98.87	6642	6634	96.28
SRR17307527	7624	7536	98.85	7335	7291	95.63
SRR17307643	8233	8174	99.28	7711	7705	93.59
SRR17307404	8614	8551	99.27	8158	8141	94.51
SRR17307364	8661	8605	99.35	8270	8270	95.49
SRR17307540	9247	9056	97.93	8949	8918	96.44
SRR17307436	9471	9380	99.04	9019	8993	94.95
SRR17307400	9513	9351	98.3	9127	9077	95.42
SRR17307649	9577	9502	99.22	9121	9114	95.17

Рис. 3: Статистика DADA2: input → filtered → denoised → non-chimeric (фрагмент таблицы, 12 из 36 образцов; образцы отсортированы по числу исходных прочтений).

- **Доля оставшихся прочтений.** До финала доживает 89.4–97.08% ридов (у большинства образцов 93–97%), то есть теряется лишь 3–11%. Это согласуется с высоким качеством по FastQC. Провальных образцов нет.
- **Самый большой и самый маленький образцы.** Исходная глубина различается почти в 9 раз: от 5128 ридов (SRR17307380) до 45 492 (SRR17307475). После всех этапов остаётся от 4809 до 43 518 ридов.
- **Вывод о качестве данных.** Сами прочтения хорошего качества, главная сложность – дисбаланс глубины секвенирования. Образец с большим числом прочтений выглядит богаче просто потому, что его прочитали глубже. Поэтому для метрик разнообразия из каждого образца случайно берётся одинаковое число прочтений: глубина 4800 (чуть ниже минимума 4809, --p-sampling-depth 4800), и все 36 образцов сохраняются.

4 Задача 4: классификатор, обученный на V4

Анализ ведётся только по прямым прочтениям длиной 251 п.н., причём после --p-trim-left 25 и --p-trunc-len 200 используются позиции 26–200 (QIIME 2 сначала усекает рид до 200 нт, затем отрезает 25 нт слева, итоговая длина $200 - 25 = 175$ нт). Рид начинается от праймера 515F (позиция ≈ 515 гена 16S по *E. coli*), и даже целиком (250 нт, до позиции ≈ 765) не доходит до V5 (≈ 820 –880). Поэтому реально проанализирован только регион V4, а V5 покрывался бы лишь прочтением R2.

Классификатор 2022.10.backbone.v4.nb.sklearn-1.4.2.qza (GreenGenes2) обучен на участке между праймерами 515F и 806R, и используемый фрагмент R1 целиком лежит внутри этого участка. Значит, классификатор соответствует фактически использованной части гена, и обучать его на V4–V5 не нужно. Классификация запускалась через SLURM (партиция AMD9554, 40 ГБ, --p-n-jobs 16, как указано в задании): на логин-узле процесс прерывался по нехватке памяти.

5 Задача 5: визуализация таксономического состава

Построен qiime taxa barplot, образцы отсортированы по level_and_time_point. Точные доли взяты из CSV barplot (Level 3 и Level 6); везде ниже – медианы по трём образцам, %.




Рис. 4: Таха barplot, уровень класса (Level 3).




Рис. 5: Таха barplot, уровень рода (Level 6).

Таблица 1: Медианные доли основных классов в первой (t1) и последней (t4) временных точках, %.

Класс	k0_t1	k5_t1	k25_t1	k0_t4	k5_t4	k25_t4
<i>Gammaproteobacteria</i>	9.6	9.9	9.2	6.6	9.6	87.1
<i>Acidobacteriae</i>	18.6	17.8	18.7	48.3	46.7	1.2
<i>Alphaproteobacteria</i>	16.9	16.1	16.8	15.9	11.8	3.2
<i>Actinomycetia</i>	10.6	10.7	10.9	5.1	12.3	1.0

Похожи ли образцы в t1? Да. Во всех трёх группах сообщество гетерогенно, ни один класс не доминирует: *Acidobacteriae* (17.8–18.7%), *Alphaproteobacteria* (16.1–16.9%), *Actinomycetia* (10.6–10.9%), *Gammaproteobacteria* (9.2–9.9%). Различия между дозами не превышают одного процентного пункта, что согласуется с общим кластером t1 на PCoA (Рис. 7): на третий день сообщество ещё не успело отреагировать на керосин.

Как меняется состав со временем?

- **k0:** заметный сдвиг происходит и в контроле: *Acidobacteriae* растут на протяжении всего года (18.6 → 35.1 → 45.3 → 48.3%), *Gammaproteobacteria* снижаются с 9.6 до 6.6%. Вероятно, это эффект длительной инкубации почвы в закрытых ёмкостях (микрокосм). Поэтому эффект керосина корректно оценивать сравнением с контролем в той же временной точке, а не с t1. Разнообразие контроля при этом остаётся высоким (Задача 7).
- **k5:** временная вспышка *Gammaproteobacteria*: 9.9% (t1) → 30.2% (t2) → 46.6% (t3), а к t4 возврат к 9.6%. *Acidobacteriae* после 26.0% (t2) и 19.7% (t3) достигают 46.7% на t4 – почти как в контроле (48.3%).
- **k25:** наиболее выраженная направленная динамика без признаков возврата: *Gammaproteobacteria* 9.2 → 32.4 → 61.8 → 87.1%, *Acidobacteriae* 18.7 → 19.1 → 6.0 → 1.2%.

Самые частые классы. В t1 – сопоставимые доли *Acidobacteriae*, *Alphaproteobacteria*, *Actinomycetia* и *Gammaproteobacteria* (лидируют *Acidobacteriae*, ≈18%). В t4 в k0 и k5 лидируют *Acidobacteriae* (48.3 и 46.7%), а в k25 абсолютно доминируют *Gammaproteobacteria* (87.1%): на остальные классы вместе приходится меньше 13%.

Самый частый род в загрязнённых образцах (Level 6). Это *Paraburkholderia* (класс *Gammaproteobacteria*, порядок *Burkholderiales*). В таксономии GreenGenes2/GTDB бывший класс *Betaproteobacteria* упразднён, и порядок *Burkholderiales* отнесён к *Gammaproteobacteria*; в классической таксономии *Paraburkholderia* относили к *Betaproteobacteria*. В среднем по всем загрязнённым образцам (k5 и k25, все точки) *Paraburkholderia* составляет 25.8% прочтений против 7.9% у следующего по обилию рода *Acidoferrum*. *Paraburkholderia* лидирует в k25 начиная с t2 и в k5 на t2–t3; в k5_t4 её обгоняет *Acidoferrum* (24.5% против 5.9%), а в контроле и во всех образцах t1 самый частый род – *Acidoferrum*.

Таблица 2: Медианные доли трёх заметных родов по трём образцам, %.

Род	Доза	t1	t2	t3	t4
<i>Paraburkholderia</i>	k0	0.3	0.2	0.3	0.2
	k5	0.2	14.9	26.1	5.9
	k25	0.2	27.3	53.7	84.2
<i>Acidoferrum</i>	k0	4.8	8.7	11.0	12.3
	k5	4.9	10.4	9.3	24.5
	k25	5.5	5.7	1.2	0.2
<i>Nevskia</i>	k0	0.0	0.0	0.0	0.0
	k5	0.0	6.3	8.8	0.7
	k25	0.0	0.0	2.1	0.0

В контроле *Paraburkholderia* практически отсутствует (0.2–0.3%). В k25 она растёт до 84.2% в t4 (по образцам 78.6, 84.2 и 88.0%), то есть 87.1% *Gammaproteobacteria* состоят почти целиком из неё. В k5 она достигает 26.1% к t3 и падает до 5.9% к t4.

Ожидаемо ли это при загрязнении керосином? Да. Керосин – смесь алканов и ароматических углеводородов, то есть внезапный источник углерода и энергии для бактерий, способных их окислять. Представители *Burkholderiales*, в том числе *Paraburkholderia*, широко известны как почвенные деструкторы углеводородов, особенно ароматических, поэтому их доля растёт именно в загрязнённых образцах и тем сильнее, чем выше доза. Ацидобактерии рода *Acidoferrum* ведут себя противоположно: в k25 вытесняются (5.5% → 0.2% с t1 до t4), а в k0 растут (4.8 → 12.3%), как и весь класс *Acidobacteriae*. Это согласуется с тем, что ацидобактерии в основном медленно растущие олиготрофы и проигрывают конкуренцию быстрорастущим таксонам при избытке доступного углерода. В k5 после спада *Paraburkholderia* *Acidoferrum* к t4 достигает 24.5%.

Род *Nevskia* (*Gammaproteobacteria*, *Nevskiales*) в контроле отсутствует, временно появляется в загрязнённой почве (до 8.8% в k5_t3 и 2.1% в k25_t3) и к t4 практически исчезает. Это пример промежуточного таксона, откликающегося на загрязнение, но не закрепляющегося в сообществе.

6 Задача 6: бета-разнообразие

Для weighted/unweighted UniFrac нужно филогенетическое дерево ASV, поэтому перед `qiime diversity core-metrics-phylogenetic` оно построено командой `qiime phylogeny align-to-tree-mafft-fasttree` (выравнивание MAFFT → маскирование переменных колонок → FastTree → укоренение по средней точке). Иллюстрация дерева – в Приложении А.




Рис. 6: PCoA по weighted UniFrac, проекция Axis 1/Axis 2, раскраска по contamination_level (k0 – красный, k5 – оранжевый, k25 – синий).




Рис. 7: PCoA по weighted UniFrac, проекция Axis 1/Axis 2, раскраска по level_and_time_point (12 групп: уровень загрязнения × время).




Рис. 8: PCoA по weighted UniFrac, проекция Axis 1/Axis 3, раскраска по level_and_time_point.

- **Axis 1 (56.53%)** – главная ось, отражает дозу: вдоль неё k0 занимает область высоких значений (справа), k25 – низких (слева), k5 между ними.
- **Axis 2 (24.66%)** отражает в основном смену во времени: у k0 и k5 более поздние точки лежат выше (Рис. 7).
- **Axis 3 (7.09%)** объясняет небольшую долю дисперсии, но в проекции Axis 1/Axis 3 (Рис. 8) на ней видна дополнительная структура. Контроль со временем смещается вниз (k0_t1 → k0_t4) почти без сдвига по Axis 1, то есть Axis 3 частично отражает дрейф самого контроля при инкубации. Загрязнённые образцы к концу эксперимента расходятся вдоль этой оси в противоположные стороны: k5 со временем поднимается (k5_t4 – выше всех), k25 начиная с t2 опускается (k25_t4 – ниже всех).
- **Первая точка (t1).** k0_t1, k5_t1 и k25_t1 образуют один тесный смешанный кластер во всех проекциях: на день 3 сообщество ещё не отреагировало на керосин.
- **Динамика.** k0_t2–t4 смещаются вправо вверх и остаются там компактно. Загрязнённые образцы отдаляются от контроля вдоль Axis 1: точка k25_t4 самая левая, то есть максимально удалена от контроля. k5_t2 и k5_t3 смещаются влево, но не так далеко, как k25.
- **Восстановление.** Для k25 его нет: k25_t4 дальше от контроля по главной оси Axis 1, чем k25_t3, и сообщество продолжает удаляться от контроля. Для k5 восстановление частичное. С одной стороны, k5_t4 по Axis 1 сдвинулась обратно к контролю, а состав вернулся к контрольному по главному классу (*Acidobacteriae* 46.7% против 48.3% в k0_t4; *Gammaproteobacteria* 46.6 → 9.6%; *Paraburkholderia* 26.1 → 5.9%). С другой стороны, k5_t4 остаётся отдельной группой: она сдвинута вверх по Axis 2, на Axis 3 находится на противоположном от k0_t4 краю, а *Paraburkholderia* всё ещё в 30 раз обильнее, чем в контроле (5.9% против 0.2%). За 360 дней сообщество k5 приблизилось к контролю, но полностью к нему не вернулось.




Рис. 9: PCoA по unweighted UniFrac, раскраска по `contamination_level` (k0 – красный, k5 – оранжевый, k25 – синий). Оси: 35.64%, 12.81%, 6.49%.

Для сравнения рассчитан unweighted UniFrac (Рис. 9): он учитывает только присутствие или отсутствие филогенетических ветвей, weighted – ещё и их обилие. По unweighted оси объясняют меньше вариации (35.64% и 12.81% против 56.53% и 24.66%), и группы разделяются хуже.

Статистическая проверка: PERMANOVA

Команда `qiime diversity beta-group-significance`, столбец `contamination_level`, `--p-method permanova --p-pairwise`, 999 перестановок, 36 образцов.

Таблица 3: PERMANOVA по уровню загрязнения: pseudo- F и q -value (для общего теста – p).

Сравнение	weighted UniFrac		unweighted UniFrac	
	pseudo- F	q	pseudo- F	q
Все группы	8.00	$p = 0.001$	2.51	$p = 0.006$
k0 – k25	14.08	0.0030	3.26	0.0165
k0 – k5	6.06	0.0045	3.27	0.0165
k5 – k25	4.68	0.0100	1.22	0.231

По weighted UniFrac значимо различаются все три пары: сильнее всего k0 и k25, слабее всего k5 и k25. По unweighted и k5, и k25 значимо отличаются от контроля, причём сопоставимо, а друг от друга не отличаются ($q = 0.231$). Значит, основная разница между дозами – в относительном обилии таксонов, а не в наборе присутствующих линий: керосин прежде всего меняет пропорции. Например, доля *Acidobacteriae* в k25 падает с 18.7% до 1.2%, но они не исчезают. Значения pseudo- F двух метрик строго сравнивать нельзя, однако разрыв (8.00 против 2.51) согласуется с этим выводом.

Ограничения теста: (1) он применён ко всем четырём временным точкам сразу, а на t1 сообщества всех доз почти одинаковы, поэтому различия между дозами занижены по сравнению с поздними точками; (2) пробы разных временных точек отбирались из одних и тех же ёмкостей и не являются независимыми; (3) PERMANOVA не отличает сдвиг центров групп от различий во внутригрупповом разбросе.

7 Задача 7: альфа-разнообразие (индекс Шеннона)

Вопрос задания – как разнообразие меняется *со временем* при разном уровне загрязнения, поэтому основная иллюстрация ниже – по столбцу `level_and_time_point` (12 групп: доза × время), а не по одному лишь уровню загрязнения.




Рис. 10: Индекс Шеннона по группам доза × время (level_and_time_point, $n = 3$ в каждой группе).

Для общей картины по дозам без учёта времени – Рис. 11.

Alpha Diversity Boxplots




Рис. 11: Индекс Шеннона по уровням загрязнения, все временные точки вместе ($n = 12$ в каждой группе).

Индекс Шеннона в QIIME 2 считается по основанию 2 и логарифмичен, поэтому наряду с H удобно смотреть на эффективное число таксонов 2^H – число равнообильных таксонов, дающих то же значение индекса.

Таблица 4: Медианы индекса Шеннона H по группам доза $\times$ время (по три образца) и эффективное число таксонов 2^H (в скобках).

Доза	t1 (день 3)	t2 (день 90)	t3 (день 180)	t4 (день 360)
k0	9.01 (516)	8.92 (484)	8.67 (407)	8.27 (309)
k5	9.03 (523)	7.83 (228)	6.68 (103)	6.84 (115)
k25	8.90 (478)	7.60 (194)	5.69 (52)	2.97 (8)

- **k0:** разнообразие медленно снижается (эффективное число таксонов $516 \rightarrow 309$), что согласуется с дрейфом состава контроля при инкубации, но остаётся самым высоким.
- **k5:** резкое падение к дню 180 ($523 \rightarrow 103$), затем стабилизация (115 на t4). Небольшой рост между t3 и t4 укладывается в разброс образцов и статистически не подтверждён.
- **k25:** разнообразие падает на каждом шаге, и спад не замедляется: наибольшее падение приходится как раз на последний интервал t3→t4 ($H: 5.69 \rightarrow 2.97$). К t4 эффективное число таксонов сокращается примерно в 60 раз ($478 \rightarrow 8$): сообщество фактически сведено к считанным доминантам, прежде всего *Paraburkholderia*.

Тест Краскела–Уоллиса (qiime diversity alpha-group-significance):

Таблица 5: Тест Краскела–Уоллиса для индекса Шеннона по разным группировкам.

Группировка	H	p
contamination_level	9.83	0.0073
day_after_contamination	21.71	$7.5 \cdot 10^{-5}$
level_and_time_point	34.13	$3.4 \cdot 10^{-4}$
replica_number	0.00	1.0

- **По уровню загрязнения:** k0 против k25 – $q = 0.0168$, k0 против k5 – $q = 0.0365$ (значимо после поправки); k25 против k5 – $q = 0.149$ (не значимо).
- **По времени:** день 3 значимо отличается от всех остальных точек ($q = 0.001$ – 0.003), а d90, d180 и d360 между собой не различаются ($q \geq 0.056$). Однако этот тест объединяет все дозы, включая контроль. Для k25 спад продолжается весь год (Табл. 4), поэтому вывод «основное падение в первые три месяца» верен только для объединённых данных, но не для сильного загрязнения.
- **По доза $\times$ время:** из 66 попарных сравнений после поправки ни одно не значимо (минимальное $q = 0.055$): в каждой группе всего по три образца, а при 3 против 3 наименьшее достижимое p у теста Краскела–Уоллиса равно 0.0495, что после поправки на 66 сравнений не может дать значимости. Различия между конкретными комбинациями (например, k5 и k25 на t4: 6.84 и 2.97) видны по медианам, но статистически не подтверждаются.
- **По номеру реплики** различий нет ($p = 1.0$), как и должно быть.

Интерпретация. Загрязнение керосином, и слабое, и сильное, значимо снижает альфа-разнообразие относительно контроля. Отсутствие значимого различия между k5 и k25 в объединённом по времени тесте не означает, что эффект дозы исчерпан: на t1 все дозы почти одинаковы, и усреднение по четырём точкам смазывает поздние различия. К

t4 эффективное число таксонов в k25 (8) в ≈ 14 раз меньше, чем в k5 (115), и в ≈ 40 раз меньше, чем в контроле (309). Широкий разброс внутри загрязнённых групп на Рис. 11 объясняется именно временной динамикой: ранние точки близки к контролю, поздние (особенно k25_t4) намного ниже из-за доминирования одного таксона (*Paraburkholderia*).

Общий вывод

- **Качество данных:** прочтения хорошего качества, после DADA2 сохраняется 89–97% ридов; все предупреждения FastQC (праймер в начале рида, дубликаты, GC) типичны для ампликонных данных. Основная сложность – 9-кратный разброс глубины, решённый разрежением до 4800 прочтений.
- **Таксономия:** в t1 все три группы близки и гетерогенны. В загрязнённых образцах со временем растёт доля деструкторов углеводов: в k25_t4 *Gammaproteobacteria* составляют 87.1%, почти целиком за счёт *Paraburkholderia* (84.2%). В k5 она достигает максимума 26.1% на t3 и падает до 5.9% к t4. Контроль тоже меняется (рост *Acidobacteriae*, вероятно из-за инкубации), но сохраняет высокое разнообразие.
- **Бета-разнообразие:** в t1 сообщества всех доз близки, затем загрязнённые расходятся с контролем вдоль Axis 1 (56.53%). PERMANOVA по weighted UniFrac подтверждает различие всех пар ($F = 8.00$, $p = 0.001$); по unweighted различия слабее ($F = 2.51$), k5 и k25 друг от друга не отличаются: керосин меняет главным образом пропорции таксонов, а не их набор.
- **Альфа-разнообразие:** и слабое, и сильное загрязнение значительно снижают индекс Шеннона относительно контроля. В k5 разнообразие падает к дню 180 и стабилизируется, в k25 падает весь год, и к t4 эффективное число таксонов в 14 раз ниже, чем в k5 (8 против 115).
- **Восстановление:** для k25 за 360 дней его нет ни по одному показателю. Для k5 есть частичное восстановление состава (лидируют *Acidobacteriae*, как в контроле; спад *Paraburkholderia*), но по Шеннону (6.84 против 8.27) и положению на PCoA сообщество к контролю не вернулось.

В совокупности эти результаты показывают, что керосиновое загрязнение сдвигает почвенное бактериальное сообщество от исходного разнообразного состояния к сообществу, обеднённому и доминируемому специализированными углеводород-деградирующими таксонами (*Paraburkholderia*). Сдвиг усиливается с дозой и временем: при сильном загрязнении он продолжается весь год, а при слабом за 360 дней обращается лишь частично.

А Филогенетическое дерево

Построение дерева необходимо для расчёта UniFrac (Задача 6), но визуализация дерева ни в одной задаче не требуется; рисунок приведён как дополнительная иллюстрация. Он построен по файлу `tree.nwk` (экспорт из QIIME 2) и таксономии `taxonomy.tsv` с помощью скрипта на Python (`matplotlib`), рисующего дерево по кругу и раскрашивающего ветви и внешнее кольцо по типу (`phylum`); на слайдах семинара для этой цели предложен `qiime empress tree-plot` - но у меня он не работал.




Рис. 12: Филогенетическое дерево 1944 ASV. Кольцо и ветви раскрашены по типу (phylum, GreenGenes2); тёмно-серые ветви объединяют ASV разных типов, светло-серые – редкие или не определённые типы. Длины ветвей не в масштабе.