# ChIP-seq анализ Foxd3:
## динамика геномного связывания в ходе развития нервного гребня *Danio rerio*

Анна Шифон
Семинар 2 «ChIP-seq», домашнее задание

27 сентября 2026 г.

## 1. Цель работы

Целью работы является анализ данных ChIP-seq транскрипционного фактора Foxd3 у эмбрионов *Danio rerio* (зебрафиш) на четырёх последовательных стадиях развития: 75% epiboly (гаструляция), 1–2 somite stage (индукция нервного гребня), 5–6 somite stage (спецификация нервного гребня) и 14 somite stage (миграция нервного гребня).

На семинаре планировалось разобрать обработку ChIP-seq данных (контроль качества, построение сигнала, peak calling, QC пиков) на примере стадии 14ss. Задача домашней работы – самостоятельно провести такой же анализ для стадий 75% epiboly и 1–2ss, а затем сравнить полученные результаты со всеми четырьмя стадиями (включая готовые данные 5–6ss, предоставленные преподавателем), чтобы проследить, как меняется картина связывания Foxd3 с геномом в процессе формирования и миграции нервного гребня, и понять, какую часть наблюдаемых различий можно уверенно считать биологической, а какую нельзя отделить от различий качества экспериментов.

## 2. Использованные данные

- **Данные семинара (14ss):** `foxd3_14ss_chip.nuclear.bam`, `foxd3_14ss_input.nuclear.bam`.
- **Данные домашнего задания (75ep и 1–2ss):** `foxd3_75ep_chip/input.nuclear.bam`, `foxd3_1-2ss_chip/input.nuclear.bam`.
- **Готовые данные преподавателя (5–6ss):** пики, сигнал и FRiP для стадии 5–6ss (`teacher/5-6ss/`), используются как готовая точка сравнения; глубина ChIP-библиотеки – 18 853 396 ридов.
- **Референс:** сборка генома GRCz11 (`GRCz11.fa`), аннотация генов (`GRCz11.gtf`), список ядерных хромосом (`nuclear_genome.bed`, суммарная длина 1 679 186 873 п.н.). Для `-g` в MACS3 в итоге использовано не это точное значение, а стандартное для семинара приближённое число `1360000000` – обоснование выбора см. в разделе 7.

Все BAM-файлы – парноконцевые (paired-end), предварительно отфильтрованы (дубликаты отсутствуют, 100% ридов картированы и корректно спарены).

**Примечание к составу референсных файлов.** На слайдах семинара в качестве референсных материалов фигурировали только `genes.bed`, `tss.bed` и `chrom.sizes`.

Файлы `GRCz11.gtf` и `nuclear_genome.bed` на слайдах не упоминались – они появились в рабочей директории уже после запуска подготовительного скрипта `00_setup_student_workspace.sh`, который создавал окружение именно для выполнения домашнего задания и, по всей видимости, включал дополнительные материалы сверх исходного набора семинара. Так как происхождение этих двух файлов не было объявлено отдельно, они использовались как предоставленные корректные референсные данные без дополнительной проверки их согласованности с материалами семинара.

# 3. Форматы файлов

| Формат | Что это и что хранит |
|---|---|
| **GTF** | Текстовая построчная аннотация генов и транскриптов: 9 колонок (seqname, source, feature, start, end, score, strand, frame, attributes). Координаты 1-based, интервал закрытый с обеих сторон. |
| **BED** | Простой построчный формат геномных интервалов: chrom, start, end (+ до 12 опциональных полей). Координаты 0-based, интервал полуоткрытый $[start, end)$. Используется для пиков, summit-ов и объединённых интервалов. |
| **BigWig (.bw)** | Бинарный, сжатый и индексированный формат непрерывного сигнала (coverage) вдоль генома. Хранит одно числовое значение на бин (в нашем случае бин 10 п.н.). Позволяет быстро отображать сигнал в IGV без чтения всего файла целиком. |
| **narrowPeak** | Формат BED6+4 – результат MACS3 `callpeak`: chrom, start, end, name, score, strand, signalValue (fold-enrichment в summit), $-\log_{10}(p)$, $-\log_{10}(q)$, positioncummit относительно start пика. |
| **peaks.xls** | Текстовый (не бинарный Excel) подробный вывод MACS3: те же пики, что в narrowPeak, но координаты 1-based и дополнительные поля (pileup, длина пика). |
| **matrix.gz** | Сжатая таблица `deepTools computeMatrix`: строки – пики (окрестность summit), столбцы – значения сигнала в бинах по 20 п.н. для каждого образца. Используется `plotHeatmap` и `plotProfile`. |

# 4. Методы

Обработка каждой стадии проводилась по единому конвейеру, идентичному для всех четырёх стадий (единые параметры бинов, порога FDR и effective genome size). Вычисления запускались через планировщик задач SLURM (`sbatch`, партиция `IXG6154-AI-common`) на выделенных вычислительных узлах, а не интерактивно на логин-узле сервера:

1. **QC исходных данных** – `samtools flagstat` для ChIP и Input BAM.
2. **Построение сигнала** – `bamCoverage` (deepTools), нормировка CPM, бин 10 п.н., отдельно для ChIP и Input.

3. **Обогащение ChIP/Input** – `bigwigCompare` (`operation log2`, `pseudocount 1`): для каждого бина $S(x) = \log_2\big((\mathrm{ChIP}(x)+1)/(\mathrm{Input}(x)+1)\big)$.
4. **Peak calling** – `macs3 callpeak` (`-f BAMPE`, `-g 1360000000`, `-q 0.01`).
5. **QC пиков** – число пиков, FRiP (Fraction of Reads in Peaks), медианный fold-enrichment и медианный $-\log_{10}(q)$.
6. **Профиль сигнала** – `computeMatrix reference-point` вокруг summit (±2000 п.н., бин 20 п.н.), `plotHeatmap`, `plotProfile`.
7. **Сравнение стадий** – `bedtools intersect` (попарные пересечения и stage-specific пики), `bedtools jaccard` (индекс Жаккара по суммарной длине в п.н.), `bedtools merge` (объединённый набор локусов), `multiBigwigSummary` (количественное сравнение CPM-сигнала по объединённому набору локусов на всех стадиях).
8. **Визуализация** – IGV (референс GRCz11, аннотация GRCz11.gtf, треки log2(ChIP/Input) и narrowPeak для всех четырёх стадий, единая шкала через Group Autoscale).

Полные команды со всеми параметрами приведены в Приложении (раздел 13).

# 5. QC и peak calling: 75% epiboly

## Качество исходных данных

| Образец | Всего ридов | Mapped | Properly paired | Дубликаты |
|---|---|---|---|---|
| ChIP (75ep) | 23 863 894 | 100% | 100% | 0 |
| Input (75ep) | 39 931 858 | 100% | 100% | 0 |

## Результаты peak calling

- Число найденных пиков: **36**.
- FRiP: **0.00017** (4 101 рид из 23 863 894).
- Медианная ширина пика: 291 п.н.
- Медианный fold-enrichment: 5.79.
- Медианный $-\log_{10}(q)$: 13.75.

Input у стадии 75ep глубже, чем ChIP (39.9M против 23.9M ридов) – это нормировано CPM-преобразованием на этапе bamCoverage, но эффективность самой иммунопреципитации (доля специфического сигнала) оценивается отдельно через FRiP.

# 6. QC и peak calling: 1–2 somite stage

## Качество исходных данных

| Образец | Всего ридов | Mapped | Properly paired | Дубликаты |
|---|---|---|---|---|
| ChIP (1–2ss) | 12 816 614 | 100% | 100% | 0 |

| Образец | Всего ридов | Mapped | Properly paired | Дубликаты |
|---|---|---|---|---|
| Input (1–2ss) | 33 460 348 | 100% | 100% | 0 |

### Результаты peak calling

- Число найденных пиков: **40**.
- FRiP: **0.00014** (1 799 ридов из 12 816 614) – самый низкий FRiP среди всех четырёх стадий.
- Медианная ширина пика: 259.5 п.н.
- Медианный fold-enrichment: 6.11.
- Медианный $-\log_{10}(q)$: 7.30.

Стадия 1–2ss имеет наименьшую глубину ChIP-библиотеки (12.8M ридов) среди всех четырёх стадий, что наряду с самым низким FRiP указывает на наименее "чистый"технически эксперимент из четырёх.

## 7. Сводное сравнение четырёх стадий

| Стадия | Пиков | FRiP | Медианная ширина, п.н. | Медианный fold-enr. | Медианный $-\log_{10}(q)$ |
|---|---|---|---|---|---|
| 75ep | 36 | 0.00017 | 291.0 | 5.79 | 13.75 |
| 1–2ss | 40 | 0.00014 | 259.5 | 6.11 | 7.30 |
| 5–6ss | 839 | 0.00236 | 306.0 | 5.52 | 7.84 |
| 14ss | 170 | 0.00162 | 309.5 | 3.29 | 11.14 |

**Ключевое наблюдение.** Число найденных пиков сильно варьирует между стадиями (36–839) и *коррелирует* с FRiP: чем выше доля "полезных"ридов, тем больше пиков статистически подтверждается. При этом медианный fold-enrichment (сила обогащения отдельного пика) остаётся примерно одинаковым на всех стадиях (3.3–6.1) и даже не самый высокий именно у 5–6ss. Это означает, что аномально большое число пиков у 5–6ss объясняется не тем, что отдельные пики там сильнее, а тем, что общий уровень фона/шума в этом эксперименте ниже, и статистика MACS3 смогла надёжно подтвердить больше слабых сигналов, которые на других стадиях "тонут"в шуме (подробнее в разделе 8.4 ниже и в разделе 11).

Все значения FRiP крайне низкие по общим меркам ChIP-seq (обычно 1–20%, здесь – 0.01–0.24%), что говорит о невысокой эффективности биотин-стрептавидиновой системы иммунопреципитации Foxd3 во всех четырёх экспериментах.

**Выбор effective genome size (`-g`).** Изначально для 75ep, 1–2ss и 14ss параметр `-g` был задан точной суммой длин ядерных хромосом (1 679 186 873 п.н., посчитана из `nuclear_genome.bed`, раздел 2), тогда как на семинаре и, по всей видимости, при подготовке готовых пиков 5–6ss преподавателем использовалось приближённое `-g 1360000000`. Чтобы устранить эту несопоставимость, все три свои стадии (75ep, 1–2ss, 14ss) были пересчитаны заново с `-g 1360000000` – то есть единым значением, совпадающим с конвенцией семинара и с данными 5–6ss. Числа в этом отчёте (включая таблицу выше)

приведены уже после этого пересчёта. Эффект пересчёта оказался умеренным: у 1–2ss результат не изменился вовсе (сильные пики определяются в основном локальным фоном $\lambda_d, \lambda_{1kb}, \lambda_{10kb}$, не зависящим от `-g`, а не $\lambda_{genome}$), у 75ep число пиков снизилось с 40 до 36, у 14ss – с 192 до 170; топовые по значимости пики и их координаты при этом практически не сдвинулись (см. раздел 10). Итоговый компромисс: точность самого параметра принесена в жертву прямой сопоставимости с данными преподавателя по 5–6ss, на которых строится центральный вывод раздела 8.4 – этот вывод от выбора `-g` не зависит, так как FRiP и количественное сравнение сигнала считаются независимо от MACS3, напрямую по BAM- и BigWig-файлам.

# 8. Сравнение genomic intervals

## 8.1. Попарные пересечения и индекс Жаккара

| Стадия A | Стадия B | Пиков A, пересекающихся с B | Jaccard (по п.н.) |
|---|---|---|---|
| 75ep | 1–2ss | 12 | 0.174 |
| 75ep | 5–6ss | 22 | 0.023 |
| 75ep | 14ss | 18 | 0.075 |
| 1–2ss | 5–6ss | 30 | 0.028 |
| 1–2ss | 14ss | 12 | 0.043 |
| 5–6ss | 14ss | 40 | 0.037 |

Наибольшее сходство по индексу Жаккара показывает пара самых близких по времени стадий – **75ep и 1–2ss (Jaccard = 0.174)**, заметно превышая все остальные пары. Это согласуется с ожиданием, что соседние по времени стадии развития должны иметь более похожую картину связывания Foxd3, чем удалённые друг от друга по времени.

**Осторожность в интерпретации низких значений.** Jaccard считает долю *суммарной длины в п.н.*, а не долю пиков, поэтому его низкое значение между сильно неравными по размеру наборами не обязательно означает почти полное исчезновение сайтов. Например, Jaccard между 5–6ss и 14ss (0.037) низкий не только из-за реальной перестройки репертуара, но и просто потому, что при 839 пиках на одной стадии и 170 на другой даже гипотетическое полное включение меньшего набора в больший всё равно дало бы невысокое значение индекса – большая по размеру стадия попросту занимает намного больше суммарной длины генома.

## 8.2. Стадийно-специфичные пики

| Стадия | Специфичных пиков | Всего пиков | Доля |
|---|---|---|---|
| 75ep | 6 | 36 | 16.7% |
| 1–2ss | 7 | 40 | 17.5% |
| 5–6ss | 773 | 839 | 92.1% |
| 14ss | 119 | 170 | 70.0% |

**Определение специфичности.** Пик считается специфичным для стадии здесь, если он не пересекается ни с одним пиком ни одной из *остальных трёх* стадий одновременно (объединение всех прочих наборов, `bedtools intersect -v` против общего файла). Это

более строгий критерий, чем попарное сравнение "специфичен относительно конкретно этой другой стадии – при попарном подсчёте число "специфичных"пиков для одной и той же стадии оказалось бы выше (например, 75ep относительно одного только 5–6ss даёт больше неперекрывающихся пиков, чем 75ep относительно объединения всех трёх остальных стадий сразу).

Высокая доля "специфичных"пиков у 5–6ss и 14ss – прямое следствие того, что у этих стадий пиков в принципе на порядок больше: даже при абсолютно одинаковой биологии часть пиков "богатой"стадии не найдёт пары среди значительно более скудных наборов других стадий. Поэтому это бинарное деление интерпретируется с осторожностью (см. раздел 8.4).

## 8.3. Пики, общие для всех четырёх стадий

Через последовательную фильтрацию (5–6ss ∩ 75ep ∩ 1–2ss ∩ 14ss) найдено **6 локусов**, независимо подтверждённых MACS3 на всех четырёх стадиях развития одновременно:

| Хромосома | Начало | Конец | Fold-enr. | $-\log_{10}(q)$ |
|---|---|---|---|---|
| NC_007113.7 | 33 275 999 | 33 276 609 | 20.31 | 112.1 |
| NC_007115.7 | 24 985 693 | 24 986 067 | 20.50 | 60.5 |
| **NC_007117.7** | **32 206 483** | **32 207 024** | **21.10** | **163.7** |
| NC_007127.7 | 7 514 877 | 7 515 445 | 18.32 | 85.9 |
| NC_007129.7 | 44 275 891 | 44 276 405 | 19.75 | 64.1 |
| NC_007131.7 | 9 427 840 | 9 428 313 | 18.12 | 64.8 |

Четыре из этих шести локусов совпадают с локусами, бывшими самыми сильными пиками уже на стадии 75ep и 1–2ss – то есть Foxd3 садится в эти места одним из первых (на этапе гаструляции) и удерживает их занятыми на протяжении всего исследованного периода развития. Это хорошие кандидаты на роль устойчивых ключевых регуляторных элементов.

## 8.4. Количественное сравнение сигнала

Бинарное деление "пик есть / пика нет"не всегда отражает истинную динамику сигнала, поэтому дополнительно был посчитан средний CPM-сигнал ChIP по объединённому набору из 982 локусов (`multiBigwigSummary`) на всех четырёх стадиях:

| Стадия | Средний CPM-сигнал по 982 локусам |
|---|---|
| 75ep | 0.232 |
| 1–2ss | 0.264 |
| **5–6ss** | **2.209** |
| 14ss | 0.241 |

Средний сигнал на стадии 5–6ss систематически примерно в 9 раз выше, чем на остальных трёх стадиях, причём это усиление проявляется практически равномерно по всем 982 проверенным локусам, а не избирательно в конкретных генах. Такая глобальная и равномерная разница гораздо лучше объясняется техническим отличием качества конкретного эксперимента 5–6ss (что независимо подтверждается заметно более высоким FRiP этой стадии), чем реальной биологической активацией Foxd3 именно в этот момент развития.

Подробное обсуждение – в разделе 11 (вопрос 2); выбор effective genome size для MACS3, на этот вывод не влияющий, обсуждается в разделе 7.

# 9. Профиль сигнала вокруг summit (heatmap и average profile)

Для каждой стадии вокруг summit каждого пика было построено окно ±2000 п.н. с шагом 20 п.н. (`computeMatrix reference-point`), на основе которого `plotHeatmap` строит тепловую карту (каждая строка – один пик, отсортированный по умолчанию по убыванию среднего сигнала ChIP) вместе со встроенным усреднённым по всем пикам профилем сигнала (верхняя часть каждого рисунка) отдельно для ChIP и для Input; дополнительно тот же усреднённый профиль независимо строился `plotProfile`. Хороший, статистически надёжный набор пиков должен давать узкий острый холм ChIP ровно в центре (на summit) и заметно более плоскую линию Input.

## 9.1. 75% epiboly

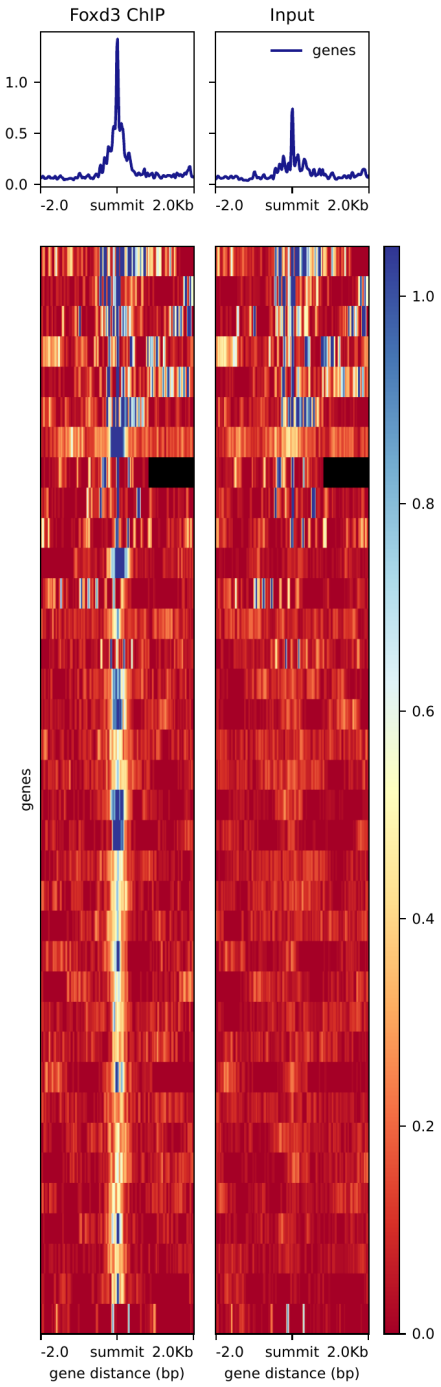



Рис. 1: Average profile и heatmap для стадии 75ep (36 пиков). Пик ChIP достигает ≈ 1.3, но в Input в этой же точке виден собственный заметный пик высотой ≈ 0.65–0.7 – около половины высоты пика ChIP. Разделение сигнала и фона на summit-ах не идеально чистое. В верхней части heatmap виден один полностью чёрный ряд – отсутствующие данные (NaN) для пика, окно ±2 kb вокруг summit которого, судя по всему, выходит за пределы короткого scaffold-а.

## 9.2. 1–2 somite stage

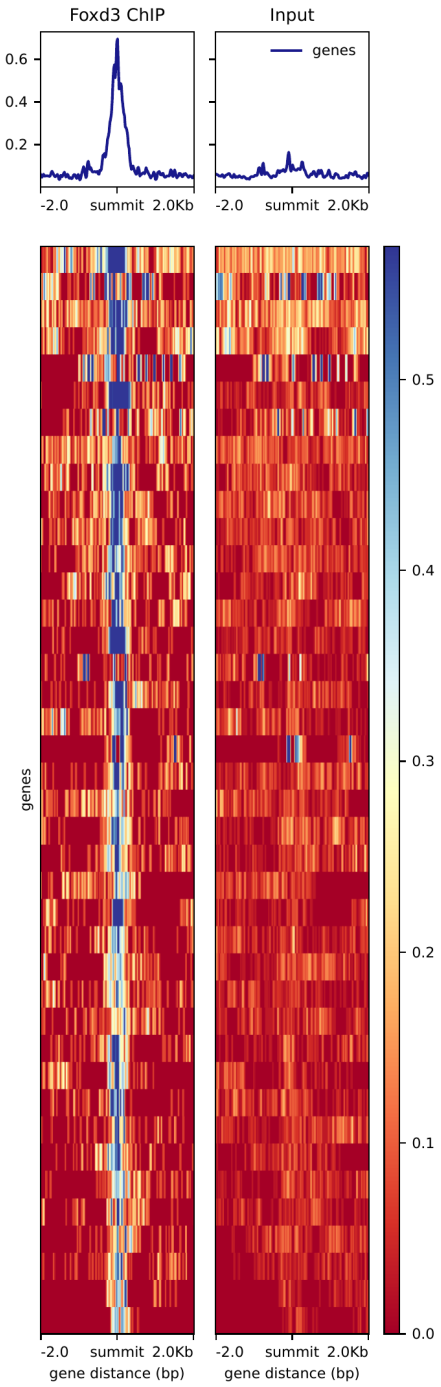



Рис. 2: Average profile и heatmap для стадии 1–2ss (40 пиков). Пик ChIP ≈ 0.6–0.7 – самый низкий в абсолютных единицах среди всех четырёх стадий (согласуется с наименьшей глубиной ChIP-библиотеки и самым низким FRiP, раздел 6). Остаточный пик Input ≈ 0.15–0.2 (примерно 25–30% от высоты ChIP) – разделение сигнала и фона заметно чище, чем у 75ep и 14ss, хотя и не такое чистое, как у 5–6ss. Пропущенных (чёрных) рядов на heatmap не обнаружено.

## 9.3. 5–6 somite stage

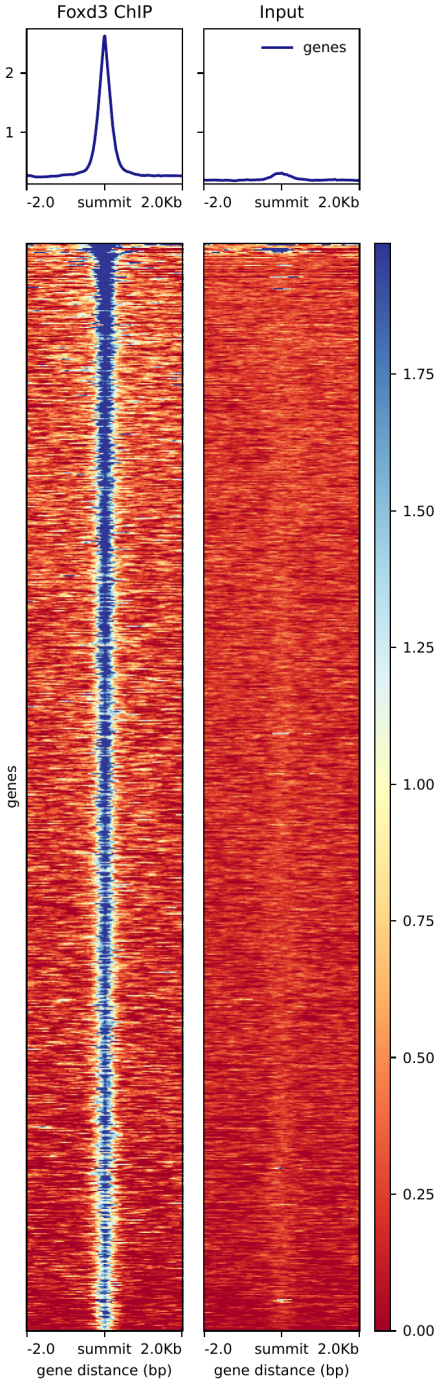



Рис. 3: Average profile и heatmap для стадии 5–6ss (839 пиков). Самый высокий и острый пик ChIP среди всех четырёх стадий (≈ 2.6–2.7), при этом Input практически плоский (максимум ≈ 0.2–0.3, ∼8–11% от высоты ChIP) – это заметно самое чистое разделение сигнал/фон среди всех стадий, и оно выдержано равномерно почти по всем 839 строкам heatmap, без единого пропущенного (чёрного) ряда.

## 9.4. 14 somite stage

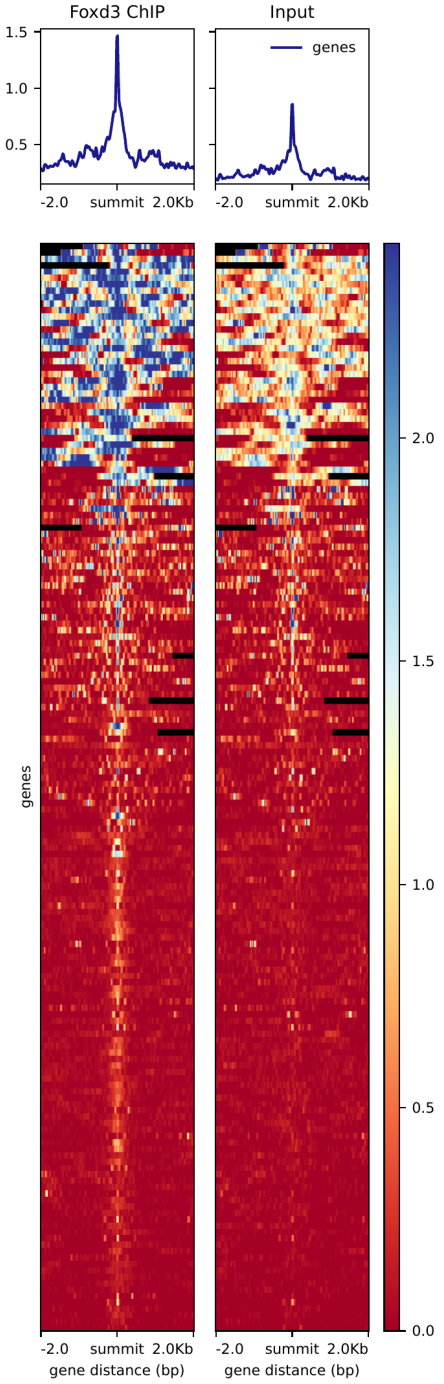



Рис. 4: Average profile и heatmap для стадии 14ss (170 пиков). Пик ChIP ≈ 1.3, но пик Input на summit-ах также заметен и составляет ≈ 0.75–0.8 (∼58–60% от высоты ChIP) – наименее чистое разделение сигнал/фон среди всех четырёх стадий по этой метрике. На heatmap видно несколько полностью чёрных рядов (заметно больше, чем у 75ep) – пропущенные данные для пиков, чьё окно ±2 kb выходит за границы коротких scaffold-ов генома. Это согласуется с тем, что часть самых значимых специфичных для 14ss пиков (раздел 8.2) расположена именно на таких коротких scaffold-ах (например, NC_007113.7 – основная хромосома, но отдельные топ-пики 14ss лежат на scaffold-ах вида NW_003336809.1 почти у самого их начала).

### 9.5. Итог по разделу

Ранжирование стадий по "чистоте"разделения ChIP и Input именно на summit-ах (от самого чистого к наименее чистому): 5–6ss $\gg$ 1–2ss $>$ 75ep $\gtrsim$ 14ss. Это независимое от FRiP наблюдение (FRiP считался по всему набору пиков и всей библиотеке в целом, а не по конкретным summit-окнам) частично, но не полностью совпадает с ранжированием по FRiP из раздела 6 (5–6ss $>$ 14ss $>$ 75ep $>$ 1–2ss): для стадии 5–6ss оба независимых показателя (FRiP и профиль на summit-ах) согласованно указывают на явно более высокое техническое качество этого эксперимента, что дополнительно подкрепляет интерпретацию из раздела 8.4. Для 14ss и 75ep порядок по двум метрикам не совпадает точно – FRiP и "чистота"именно summit-профиля отражают немного разные аспекты качества данных (первый – глобальную долю специфического сигнала во всей библиотеке, второй – локальное соотношение сигнал/фон непосредственно в уже найденных пиках), поэтому их частичное несовпадение ожидаемо и не противоречит общему выводу о существенной роли технического качества в наблюдаемых различиях между стадиями.

## 10. Визуализация в IGV

Референсный геном GRCz11 и аннотация GRCz11.gtf были загружены в IGV вместе с четырьмя треками log2(ChIP/Input) и четырьмя треками narrowPeak (по одной паре на каждую стадию). Для честного визуального сравнения высоты сигнала между стадиями для всех четырёх BigWig-треков была применена опция **Group Autoscale** (единая шкала).

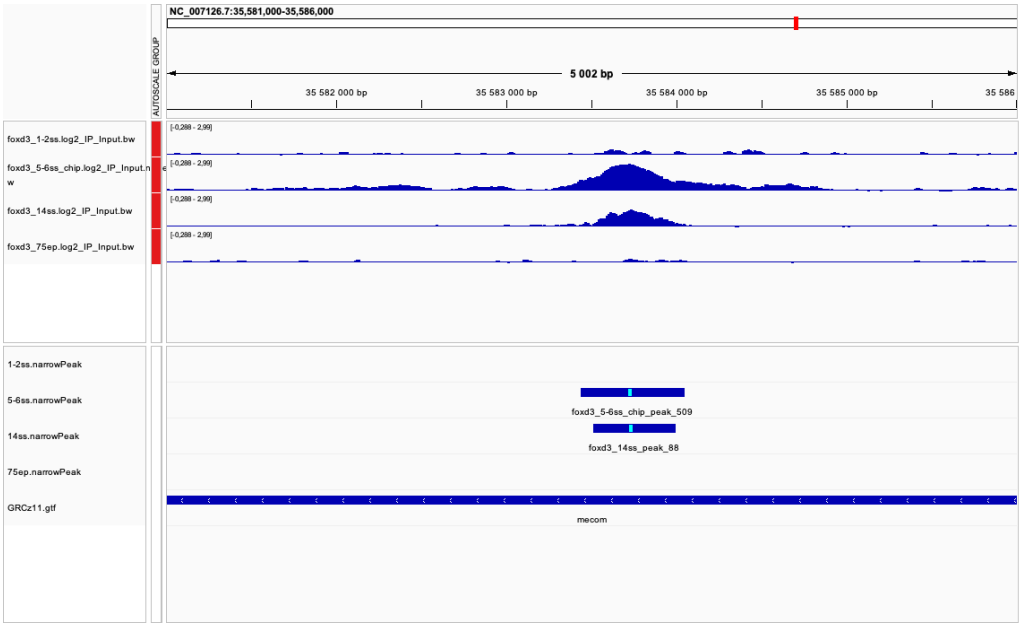



Рис. 5: Локус NC_007126.7:35 581 000–35 586 000 (ближайший ген *mecom*), где независимо вызван пик сразу на двух стадиях: **14ss** (foxd3_14ss_peak_74, $-\log_{10}(q) = 321.45$ – самое высокое значение среди вообще всех пиков всех четырёх стадий в данной работе) и **5–6ss** (foxd3_5-6ss_chip_peak_509, $-\log_{10}(q) = 77.95$ – заметно ниже, но тоже статистически надёжно). Пик отсутствует как формальный вызов на 1–2ss и 75ep, хотя лёгкий сопутствующий сигнал на сигнальных треках заметен уже на этих ранних стадиях. Все четыре трека показаны на единой шкале (Group Autoscale).

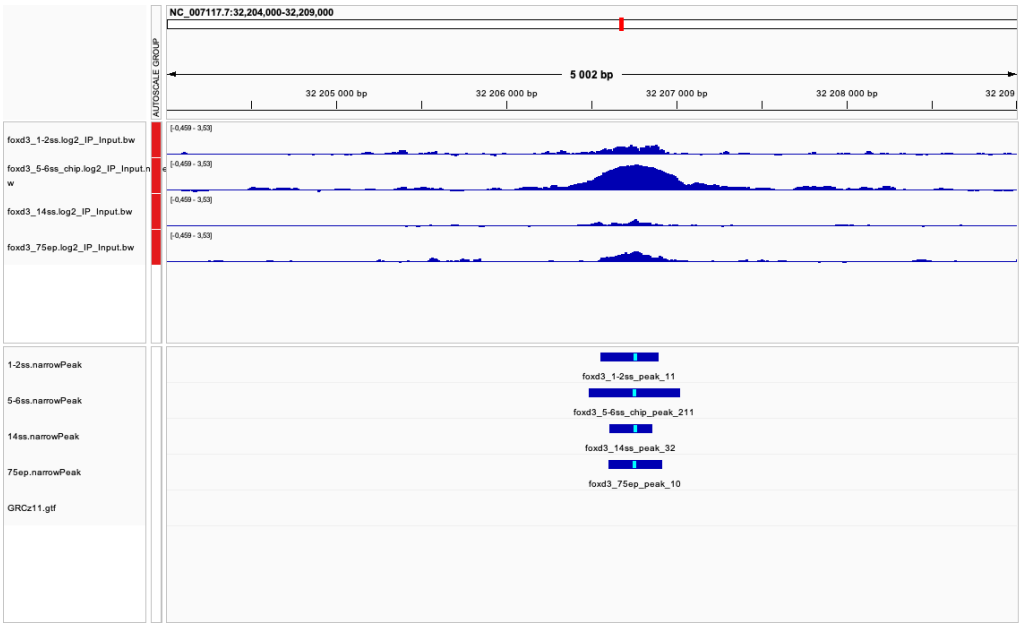



Рис. 6: Один из 6 локусов, устойчиво занятых Foxd3 на протяжении всего исследованного периода развития (NC_007117.7:32 204 000–32 209 000). MACS3 независимо подтвердил пик на всех четырёх стадиях: foxd3_75ep_ peak_10, foxd3_1-2ss_peak_11, foxd3_5-6ss_chip_peak_211, foxd3_14ss_peak_32. Ген в аннотации GTF в этом месте не обнаружен, что может указывать на дистальный регуляторный элемент (энхансер), а не на промоторный пик.

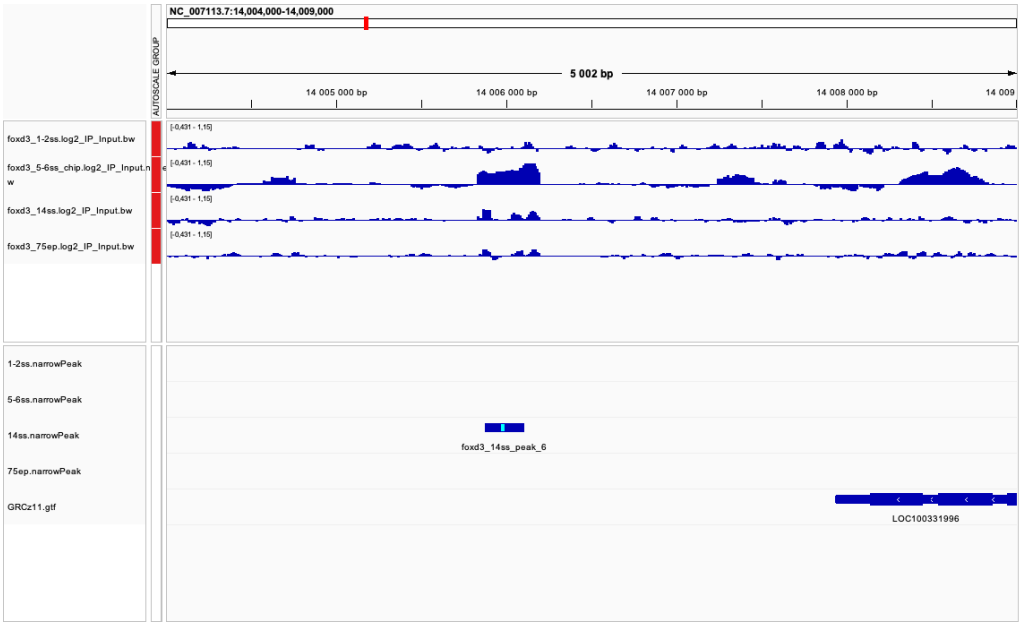



Рис. 7: Пик, статистически подтверждённый только на стадии 14ss (локус NC_007113.7:14 005 869–14 006 106, ближайший ген *LOC100331996*, $-\log_{10}(q) = 33.55$). На сигнальных треках заметен слабый сопутствующий сигнал и на других стадиях (особенно на 5–6ss), что указывает на постепенный, а не резко бинарный характер появления этого сайта связывания – статистический порог мог не быть пройден на более ранних/менее качественных экспериментах.

# 11. Биологическая интерпретация

## 1. Остаётся ли Foxd3 binding landscape постоянным в ходе развития?

Нет. Число найденных пиков меняется от 36–40 (75ep, 1–2ss) до 839 (5–6ss) и 170 (14ss) – ландшафт связывания явно не статичен. При этом часть сайтов (как минимум 6 надёжно подтверждённых локусов, раздел 8.3) остаётся занятой на протяжении всего исследованного периода, тогда как другие сайты (например, локус рядом с *LOC100331996*) статистически подтверждаются только на отдельных стадиях, а некоторые сильные локусы (например, рядом с геном *mecom*, раздел 10) подтверждены лишь на части стадий (5–6ss и 14ss).

## 2. На какой стадии наблюдается наиболее выраженный Foxd3 ChIP signal?

Формально – на стадии 5–6ss (наибольшее число пиков, наибольший средний CPM-сигнал по объединённому набору локусов, самый высокий FRiP). Однако, как показано в разделе 8.4, эта "выраженность"в значительной мере является следствием более высокого технического качества именно этого эксперимента, а не обязательно пика реальной биологической активности Foxd3 именно в этот момент (раздел 9 – heatmap/profile этой стадии независимо подтверждают самое чистое разделение ChIP/Input сигнала среди всех четырёх стадий). Отдельно стоит отметить, что этот вывод нельзя списать на простую разницу в глубине секвенирования: глубина ChIP-библиотеки 5–6ss (18.9M) меньше, чем у 75ep (23.9M) и особенно чем у 14ss (41.5M), и лишь немного больше, чем у 1–2ss (12.8M) — стадии с наименьшим числом пиков (раздел 6). Прямой монотонной связи между глубиной библиотеки и числом найденных пиков нет: наименьшая по глубине стадия (1–2ss) даёт минимум пиков, а наибольшая по глубине (14ss) — заметно больше пиков, чем 75ep и 1–2ss, но на порядок меньше, чем 5–6ss. Это говорит о том, что дело именно в специфичности/эффективности иммунопреципитации (что и отражает FRiP как доля), а не в объёме данных.

## 3. Какие участки выглядят стабильными между стадиями?

6 локусов, прошедших последовательную фильтрацию по всем четырём стадиям (раздел 8.3), в том числе локус NC_007117.7 без ближайшего аннотированного гена в GTF (раздел 10, скриншот с регионом, общим для нескольких стадий – предположительно дистальный энхансер). Ген для остальных пяти локусов из этого списка отдельно не проверялся. Эти участки, вероятно, представляют собой ключевые, "постоянно нужные"регуляторные элементы, которые Foxd3 удерживает занятыми независимо от стадии.

## 4. Какие участки появляются или исчезают?

Пример появления нового сайта – локус NC_007113.7:14 005 869– 14 006 106 рядом с геном *LOC100331996*, подтверждённый как пик только на стадии 14ss (стадия миграции нервного гребня). Это может отражать активацию нового регуляторного контура именно на этапе миграции. Вместе с тем на сигнальных треках слабый сопутствующий сигнал в этом месте виден и на более ранних стадиях, поэтому нельзя исключить, что это не резкое появление "с нуля а постепенное усиление сигнала, пересёкшее статистический порог только на 14ss.

### 5. Почему ChIP-seq сам по себе не позволяет заключить, что Foxd3 активирует или репрессирует ближайший ген?

ChIP-seq отвечает только на вопрос *где в геноме связан белок*, но не на вопрос *что это связывание делает*. Несколько причин, почему вывод о регуляции не следует напрямую:

- **Binding ≠ regulation**: наличие пика означает обогащение белка в данной области, но не доказывает, что связывание активирует или подавляет транскрипцию.
- **Peak ≠ target gene**: ближайший к пику ген не обязательно является настоящей мишенью – дистальный энхансер может регулировать ген, расположенный на десятки-сотни тысяч п.н. дальше (пример – локус NC_007117.7 без ближайшего гена в аннотации в скриншоте 2).
- **Не видно состояния хроматина**: ChIP-seq Foxd3 не говорит, открыт ли участок хроматина и активен ли энхансер (для этого нужен ATAC-seq и H3K27ac ChIP-seq).
- **Не видно результата на уровне РНК**: даже если Foxd3 связывается с регуляторным участком, из ChIP-seq нельзя понять, меняется ли экспрессия соответствующего гена.

### 6. Какие дополнительные данные нужны для проверки функционального эффекта связывания Foxd3?

- **ATAC-seq** – покажет, открыт ли хроматин в местах связывания Foxd3, и как доступность хроматина меняется при потере Foxd3 (foxd3 mutant).
- **H3K27ac ChIP-seq** – покажет, активен ли энхансер в данном локусе.
- **RNA-seq** (bulk и/или single-cell) – покажет, меняется ли экспрессия ближайших генов в ответ на связывание/потерю Foxd3, то есть замкнёт цепочку "связывание → функция".

## 12. Вывод

Геномный ландшафт связывания Foxd3 у *Danio rerio* заметно меняется в ходе формирования и миграции нервного гребня: число статистически подтверждённых сайтов связывания варьирует от 36–40 (ранние стадии 75ep и 1–2ss) до 839 (5–6ss) и 170 (14ss). Часть этих различий – как минимум существование устойчивого ядра из 6 локусов, занятых Foxd3 на всех четырёх стадиях подряд, а также наибольшее сходство ближайших по времени стадий (75ep и 1–2ss, наибольший индекс Жаккара) – можно уверенно интерпретировать как реальную биологию: Foxd3 рано "выбирает"ключевые регуляторные точки и удерживает их занятыми на протяжении значительной части развития, при этом постепенно вовлекая дополнительные, более многочисленные сайты.

Однако значительная часть наблюдаемых количественных различий между стадиями – в первую очередь аномально большое число пиков и почти десятикратно более высокий средний сигнал на стадии 5–6ss – не может быть надёжно отделена от различий в техническом качестве конкретных ChIP-seq экспериментов. Независимая метрика FRiP, измеренная для каждой стадии отдельно, коррелирует с числом найденных пиков практически идеально, а рост среднего сигнала на 5–6ss проявляется равномерно почти по всем проверенным локусам генома, что гораздо больше похоже на общий технический сдвиг (например, более эффективное биотин-стрептавидиновое вытягивание в этой конкретной партии эксперимента), чем на избирательную биологическую активацию – при этом простую разницу в глубине секвенирования как причину можно исключить: глубина

ChIP у 5–6ss (18.9M) не является ни наибольшей, ни наименьшей среди четырёх стадий и заметно уступает глубине 14ss (41.5M), которая при этом дала на порядок меньше пиков. Кроме того, все четыре эксперимента имеют крайне низкий по общим меркам FRiP (0.01–0.24%), что указывает на невысокую специфичность иммунопреципитации во всех образцах в целом и требует осторожности при любой количественной (а не только бинарной) интерпретации связывания Foxd3.

Для надёжного разделения технического шума и настоящей биологической динамики, а также для перехода от "где связан белок"к "что это связывание делает необходимы дополнительные данные – ATAC-seq, H3K27ac ChIP-seq и RNA-seq на тех же стадиях развития, что и использовано в оригинальной статье.

# 13. Приложение: использованные команды

## Effective genome size

Точная сумма длин ядерных хромосом была посчитана, но в итоге не использована в `-g` – вместо неё для сопоставимости с данными 5–6ss и конвенцией семинара выбрано `-g 1360000000` (обоснование – раздел 7):

```
awk '{sum+=$3-$2} END {print sum}' reference/nuclear_genome.bed
# 1679186873
```

## QC исходных данных

```
samtools flagstat data/<stage>/foxd3_<stage>_chip.nuclear.bam
samtools flagstat data/<stage>/foxd3_<stage>_input.nuclear.bam
```

## Построение сигнала (CPM)

```
bamCoverage -b data/<stage>/foxd3_<stage>_chip.nuclear.bam \
  -o results/signal/foxd3_<stage>_chip.CPM.bw \
  --normalizeUsing CPM --binSize 10 --numberOfProcessors 4

bamCoverage -b data/<stage>/foxd3_<stage>_input.nuclear.bam \
  -o results/signal/foxd3_<stage>_input.CPM.bw \
  --normalizeUsing CPM --binSize 10 --numberOfProcessors 4
```

## log2(ChIP/Input)

```
bigwigCompare \
  -b1 results/signal/foxd3_<stage>_chip.CPM.bw \
  -b2 results/signal/foxd3_<stage>_input.CPM.bw \
  --operation log2 --pseudocount 1 --binSize 10 \
  --numberOfProcessors 1 \
  -o results/signal/foxd3_<stage>.log2_IP_Input.bw
```

## Peak calling (MACS3)

```
macs3 callpeak \
  -t data/<stage>/foxd3_<stage>_chip.nuclear.bam \
  -c data/<stage>/foxd3_<stage>_input.nuclear.bam \
  -f BAMPE -g 1360000000 -n foxd3_<stage> -q 0.01 \
  --outdir results/peaks
```

## FRiP

```
TOTAL=$(samtools view -c data/<stage>/foxd3_<stage>_chip.nuclear.bam)
INPEAK=$(samtools view -c -L results/peaks/foxd3_<stage>_peaks.narrowPeak \
  data/<stage>/foxd3_<stage>_chip.nuclear.bam)
awk -v a=$INPEAK -v b=$TOTAL 'BEGIN{printf "FRiP = %.5f\n", a/b}'
```

## Профиль сигнала вокруг summit

```
computeMatrix reference-point --referencePoint center \
  -R results/peaks/foxd3_<stage>_summits.bed \
  -S results/signal/foxd3_<stage>_chip.CPM.bw \
     results/signal/foxd3_<stage>_input.CPM.bw \
  -b 2000 -a 2000 --binSize 20 \
  -o results/figures/foxd3_<stage>.matrix.gz

plotHeatmap -m results/figures/foxd3_<stage>.matrix.gz \
  -out results/figures/foxd3_<stage>.heatmap.pdf \
  --samplesLabel "Foxd3 ChIP" "Input" --refPointLabel "summit"

plotProfile -m results/figures/foxd3_<stage>.matrix.gz \
  -out results/figures/foxd3_<stage>.profile.pdf \
  --samplesLabel "Foxd3 ChIP" "Input" --refPointLabel "summit"
```

## Попарные пересечения и Jaccard

```
for A in 75ep 1-2ss 5-6ss 14ss; do
  for B in 75ep 1-2ss 5-6ss 14ss; do
    [ "$A" = "$B" ] && continue
    n=$(bedtools intersect -a $A.narrowPeak -b $B.narrowPeak -u | wc -l)
    j=$(bedtools jaccard -a $A.sorted.bed -b $B.sorted.bed | tail -1 | cut -f3)
    echo -e "$A\t$B\t$n\t$j"
  done
done
```

## Stage-specific пики

```
for S in 75ep 1-2ss 5-6ss 14ss; do
  cat $(ls *.narrowPeak | grep -v "^$S.narrowPeak$") \
    | sort -k1,1 -k2,2n > others_$S.bed
  bedtools intersect -a $S.narrowPeak -b others_$S.bed -v > only_$S.bed
done
```

### Пики, общие для всех четырёх стадий

```
bedtools intersect -a 5-6ss.narrowPeak -b 75ep.narrowPeak -u \
 | bedtools intersect -a stdin -b 1-2ss.narrowPeak -u \
 | bedtools intersect -a stdin -b 14ss.narrowPeak -u > common_all4.bed
```

### Количественное сравнение сигнала

```
cat 75ep.narrowPeak 1-2ss.narrowPeak 5-6ss.narrowPeak 14ss.narrowPeak \
  | cut -f1-3 | sort -k1,1 -k2,2n | bedtools merge > union.bed

multiBigwigSummary BED-file \
  -b foxd3_75ep_chip.CPM.bw foxd3_1-2ss_chip.CPM.bw \
     foxd3_5-6ss_chip.nuclear.CPM.bw foxd3_14ss_chip.CPM.bw \
  --labels 75ep 1-2ss 5-6ss 14ss --BED union.bed \
  -o union.npz --outRawCounts union_signal.tab
```